ARGOS
제작과 개선 연구
최종보고서

DGX 구상에서 임대 GPU 본실험, 수학 회복과 연구 동결까지

검증한 다중 교사의 답변으로 작은 학생 모델을 만들고, 실제 실패와 수학 회복까지 추적한 최종 기록이다. 초기 설계·임대 GPU·전체 비교·AI 검수·통계·비용과 시간을 한 흐름으로 정리했다. 성능의 일부 개선과 독립 검증의 한계를 함께 공개한다.

구분	기록
연구 상태	추가 학습·후보 선택 종료, 결과 동결
기준일	2026년 10월 27일
비용·장비 가동	사용자 보고 총40달러 / PC4일·96시간
검수와 협업	AI 검수와 웹 프로젝트 Pro 대조 / 독립 사람 검수0명

연구 질문과 예산·중단·공개 결정: 프로젝트 연구자
코드·실행·분석·문서 지원: Codex / 설계·해석·역사 검토: ChatGPT

공개 연구 저장소

읽는 순서와 목차

핵심 결과는1–2절, 제작 과정은6–22절, 보완 실험은23–39절, 주장·선호·통계는40–44절, 비용·시간·결론은45–50절에 정리했다. 그림과 표는 해당 절의 근거 파일·표본 범위에 연결된다.

읽는 순서와 목차 **2**

I. 연구의 결론과 범위 **5**

01. 초록: 제작과 수학 점수 회복을 확인했지만 전반적 우월성은 입증하지 못했다 . . . 5

02. 같은 후속 개발 문항에서 본 마지막 상태 . . . 5

03. 연구 질문과 성공을 판단하는 단위 . . . 6

04. CoMPaSS와 ARGOS, 그리고 실제로 만든 모델 . . . 6

05. 조사 방법: 계획, 당시 기록, 실행 증거, 회고를 대조했다 . . . 7

II. 연구를 어떻게 만들었는가 **7**

06. 8월의 설계부터 10월의 임대 GPU와 동결까지 . . . 7

07. 사용자·웹 ChatGPT·Codex의 역할 . . . 9

08. 계획을 그대로 따르지 않고 바꾼 사항 . . . 9

09. 8월 9일에 정리된 비교 통제와 데이터 계약 . . . 10

10. 8월 교사 파일럿: 계획 60문항과 분석 50응답 . . . 11

11. PASS 30개로 실제 학생 어댑터를 만들다 . . . 11

12. 첫 평가의 노출 문제를 차단하고 새 20문항으로 확인하다 . . . 12

13. 문서를 보존하고 클라우드 실행부를 다시 설계하다 . . . 12

14. 실제 A40 임대에서 드러난 저장 공간·추론 설정 문제 . . . 13

III. 임대 GPU에서 만든 원래 ARGOS **13**

15. 48GB에서 24GB로 옮긴 실제 이유와 실행 범위 . . . 13

16. 응답 생성·회수·제외·검증을 맞춘 데이터 장부 . . . 14

17. 검증 통과 데이터도 학습에 필요한 정보를 잃을 수 있다 . . . 15

18. 열 개의 학생 학습은 독립된 비교 실험이었다 . . . 15

19. 13개 조건에서 의미 정확도와 형식 통과가 갈라졌다 . . . 16

20. 일부 표본에서는 교사를 앞섰다는 관측도 보존한다 . . . 18

21. 동결 S5의 새 240문항과 공개 120문항은 실제 실행했다 . . . 19

22. 409개 주장과 40쌍의 보조 검수는 다른 성과를 보여 줬다 . . . 20

IV. 손실을 확인하고 개선을 시도한 과정 20

23. 수학이 낮아진 현상을 원인과 구분해 진단하다 . . . 20

24. 기존 140문항을 활용한 앞선 보완과 승격 실패 . . . 21

25. 같은 이름의 평가셋들을 하나로 합치지 않는다 . . . 21

26. 기본 모델과 두 교사의 기준선을 먼저 다시 세우다 . . . 22

27. 개발 176문항과 공개 정답 오류 민감도 . . . 23

28. A4·B4·C5: 정답만, 설명 포함, 유지 자료 혼합 . . . 23

29. 세 학습·여섯 저장본과 마지막 R6까지 전체 비교 . . . 24

30. 후보가 좋아 보이더라도 승격 기준을 통과해야 한다 . . . 26

31. 웹 GPT의 반론으로 AI 채점의 일관성을 바로잡다 . . . 26

V. 마지막 한 차례: R6 회복 실험 27

32. 마지막 실험 전, 어댑터 강도만 바꿔 손실을 확인하다 . . . 27

33. 계산 단계를 드러낸 960행을 새 기반 모델에 학습하다 . . . 27

34. 재측정 기준선과 선정 하한을 후보 결과 전에 고정하다 . . . 28

35. 120단계 한 번, 세 체크포인트,6분 48초의 학습 . . . 28

36. 부분 회복은 컸지만 전체 승격 요건은 충족하지 못했다 . . . 28

37. 청구액은 회복했지만 가중점수 손실이 남았다 . . . 29

38. 같은 문항의 이득과 손실을 나누면 순차이가 설명된다 . . . 30

39. 정답을 맞히고도 계산·인용이 틀린 답을 구분하다 . . . 31

VI. 주장·선호·통계로 다시 읽는 성과 **32**

40. 798개 주장 감사: 짧은 답과 낮은 오류율은 같은 말이 아니다 . . . 32

41. 72쌍·두 AI의 판정: 종합 선호와 자연스러움의 일치가 달랐다 . . . 33

42. 실행 시간과 자원 효율의 측정 범위 . . . 33

VII. 동결·비용·시간과 연구의 완결 **34**

43. 봉인한 최종 280문항은 실행하지 않고 연구를 동결했다 . . . 34

44. 통계가 말해 주는 것과 말해 주지 않는 것 . . . 35

45. 전체 40달러와 마지막 차수의 계정 차감은 범위가 다르다 . . . 35

46. 얼마나 시간을 쏟았는가: 기록으로 산출 가능한 범위 . . . 36

47. 공개 보고서에서 재계산할 수 있는 범위 . . . 37

48. 최종 질문에 대한 답: 향상, 회복, 교사 초월 . . . 38

49. 미수행 평가와 남아 있는 불확실성 . . . 38

50. 연구를 마감하며: 성능 성공과 연구 완결은 다르다 . . . 38

VIII. 자료와 재현 안내 **39**

51. 자료 색인과 주요 방법 문헌 . . . 39

I. 연구의 결론과 범위

01. 초록: 제작과 수학 점수 회복을 확인했지만 전반적 우월성은 입증하지 못했다

ARGOS는 공개 기반 언어모델 EXAONE-3.5-7.8B-Instruct 위에 검증한 교사 응답과 보충 자료를 학습시킨 학생 모델·어댑터 계열이다. 본 연구는 서로 다른 두 교사의 응답을 검증하여 통합하면 제한된 계산 자원에서도 유용한 개선을 얻을 수 있는지 탐구했다. 초기 DGX 구상과 소규모 파일럿을 거쳐, 실제 본실험은 임대한 A40·A5000 GPU와 로컬 RTX5060Ti를 이용해 수행했다.

원래 ARGOS는 일부 자료 충실도·정확 출력·정치 및 자료 기반 표본에서 이득을 보였지만 큰 수학 손실도 나타냈다. 마지막 회복 실험 R6는 같은 후속 개발 GSM8K 40문항에서 기존 ARGOS의 6개 정답에 비해 34개를 맞혔다. 정답률은 15%에서 85%로 70%p 높아졌으나, 이는 같은 모델을 연속으로 학습한 단일 곡선이 아니라 같은 기반 모델에서 새로 만든 후보들의 비교이다. 재측정 기본 모델 35개와 교사 38·39개보다 낮았고, 문서 과제도 기본 모델에 미치지 못했다.

세 R6 저장본 중 전체 승격 요건을 충족한 후보는 없었다. 새 합성 200문항과 이전 미사용 공개 80문항은 봉인했지만 최종 추론은 수행하지 않았다. 따라서 본 연구는 실제 제작·학습·평가와 부분 회복, 부정적 결과 및 미실행 범위를 함께 기록한 개발 연구로 마감한다. 비용 40달러와 PC 연속 가동 96시간은 사용자 보고이며, 독립 사람 검수자는 0명이다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: current-conclusion

02. 같은 후속 개발 문항에서 본 마지막 상태

아래 표는 문서 96개, GSM8K 40개, KoBEST 40개의 정답 수이다. 유효 설명은 문서 정답과 설명 기준을 함께 충족한 수이다. S0와 R6는 마지막 GPU 실행에서 다시 측정했으며, 기존 ARGOS·B4·두 교사 행은 같은 개발 문항의 앞선 실행에서 가져왔다. 모든 후보·조건을 포함한 13행 표는 29절에 제시한다.

R6-120은 B4-075보다 문서 정답 2개·수학 2개·유효 설명 4개가 늘었지만 KoBEST 공식 점수는 1개 낮다. R6-080의 문서 57개와 R6-120의 수학 34개를 합쳐 한 모델의 성능으로 표시하지 않는다. 이 표의 공개 벤치마크 결과는 각 40문항 표본이며 전체 벤치마크 점수가 아니다. 모델별 보정으로 선택된 지시문과 교사의 추론 엔진·양자화가 달라 완전히 동일한 실행 조건의 인과 실험도 아니다.

모델	문서 /96	설명 /96	수학 /40	Ko /40	수정 /40
S0	68	42	35	36	37
기존 ARGOS	35	25	6	37	38
B4-075	53	40	32	37	38
R6-040	46	23	34	36	37
R6-080	57	45	31	36	37
R6-120	55	44	34	36	37
GPT-OSS 20B	93	87	38	35	36
GLM 4.7 Flash	86	72	39	37	38

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: current-results

03. 연구 질문과 성공을 판단하는 단위

핵심 가설은 교사의 수를 늘리면 자동으로 성능이 좋아진다는 것이 아니었다. 같은 학생 모델과 같은 질문에서 검증된 교사 답을 학습하는 조건이 품질을 보지 않고 고른 교사 답을 학습하는 조건보다 유리한지를 묻는 것이 중심이었다. 한국어 자료 추가, 작은 학생의 부분적 교사 초월, 제한된 자원에서의 실행 가능성은 별도의 질문이었다.

이 질문들은 다른 비교를 필요로 한다. S0와 S5의 차이에는 교사 선택·검증·답변 가공·추가 QA·학습·사후 선정이 함께 들어간다. 이를 검증 하나의 효과로 부르면 안 된다. 반대로 일부 문항의 점수가 낮다고 검증 자체가 무효라고 결론낼 수도 없다. 본문은 사전에 의도한 통제 비교와 실제 제작한 모델의 실용 성능을 함께 보여 준다.

질문	적절한 비교	이번 결과
검증한 다중 교사가 미검증 다중 교사보다 좋은가?	동일7779질문: S3_matched 대 S4_teacher_only	관측2시드의 동시 통과율 우위를 확인하지 못함
한국어 자료 추가가 도움이 되는가?	S4 full, S5 한국어500, S5 general 영어500	언어·내용·자료 출처가 함께 달라 순수 언어 효과 분리 불가
기반 모델·교사를 넘는가?	의미 정답·지시·설명·유지 과제를 따로 비교	일부 과제의 관측 우세는 있으나 전반 우월성 미입증
수학 손실을 회복할 수 있는가?	같은 개발 GSM8K40: 기존6, S0 35, R6 34	점수의 큰 부분 회복. 동등성·독립 일반화 입증은 아님

근거: 계획서의 연구 질문과 완료된 단계별 결과 · 공개 데이터 키: synthesis-questions

04. CoMPaSS와 ARGOS, 그리고 실제로 만든 모델

CoMPaSS는 학교 집중탐구와 연구 프로젝트의 이름으로 사용됐고, CoMPaSS-AI는 저장소·파이프라인 표기다. ARGOS는 그 안에서 만든 학생 모델과 어댑터 계열의 이름이다. 초기 산출물 ARGOS-Pilot, 원래 본 실험의 대표 S5_general_control, 이후 A4/B4/C5와 R6 후보를 구분한다. 이름이 같다고 모든 결과를 한 체크포인트의 성능으로 합치지 않는다.

ARGOS는 처음부터 거대 모델 전체를 사전학습한 산출물이 아니다. 고정한 EXAONE 기반 가중치와 학습한 LoRA 어댑터를 결합해 작동한다. 학습 목표는 보이는 정답·설명 텍스트에 대한 completion-only 지도 미세조정이다. 교사 내부 상태·로짓·비공개 추론 채널을 그대로 이전한 방식으로 표현하지 않는다.

웹 프로젝트 검색에는 ARGOS의 영문 풀이와 명명 대화 단서가 있었지만, 원대화 전체와 정확한 제목을 이번에 확보하지 못했다. CoMPaSS의 공식 약자 풀이도 확인되지 않았다. 따라서 이름의 역할만 확정적으로 설명하고, 그럴듯한 어원을 새로 만들어 붙이지 않았다.

근거: 첨부된 DOCX 두 파일의 직접 읽기와 SHA-256 · 공개 데이터 키: synthesis-source-register

05. 조사 방법: 계획, 당시 기록, 실행 증거, 회고를 대조했다

이번 종합 보고서는 첨부된 초기·수정 계획서, Git 커밋과 설계 문서, 보존된 8월 실행 도구 출력,10월 학습·추론·채점·백업 기록, 이미 공개한 집계 자료를 대조해 작성했다. 실행 수치에는 현재 읽을 수 있는 원자료·해시·영수증을 우선했다. 외장 드라이브의 8월 원본을 다시 열 수 없는 부분은 당시 파일을 읽었던 도구 출력의 복원이라는 증거 수준을 표시했다.

사용자의 요청에 따라 기존 compass ai 웹 프로젝트의 Pro와 두 차례 대화했다. 첫 번째는 초기·중기 문서를 조사하고 접근 가능한 기록의 범위를 구분하는 작업이었다. 두 번째는 Codex가 확인한 커밋·R6·비용·시간 집계를 전달해 해석을 조율했다. 웹 GPT의 문서 검토는 원시 실행 로그의 별도 재감사나 독립 사람 검수가 아니다.

합의 과정에서 초기 통제 설계는 8월 9일에 이미 문서화됐다는 점, DGX 하드웨어가 과거 메타데이터로 독립 확인되지 않는 점, 활동 구간 13.92시간을 사람 노동시간으로 바꾸면 안 된다는 점을 반영했다. 계획 문서에 적힌 실행 지시는 당시 설계의 증거로 읽었으며 현재의 중단·마감 요청보다 우선하지 않았다.

자료	문서	SHA-256
PLAN1	초기 CoMPaSS 집중탐구계획서	7ba040f58662692b24a1779e46e31cada0255224b5a5e604e5877bb08146e4f3
PLAN2	2026-10-22 클라우드 GPU 5일 수정계획서	86954f0b54aa9ce4b482c1e572a02768e1af81608c3244a2326c2a77c94ad252

근거: 첨부된 DOCX 두 파일의 직접 읽기와 SHA-256 · 공개 데이터 키: synthesis-source-register

II. 연구를 어떻게 만들었는가

06. 8월의 설계부터 10월의 임대 GPU와 동결까지

로컬에서 직접 확인한 가장 이른 Git 커밋은 8월 9일 16:40 KST의 7a1037a이다.8월 10일 23:52의 0d0ce83,8월 11일 01:11의 58aa24b로 초기 프로토콜과 실행 준비가 이어졌다. 설계 문서와 커밋이 남긴 날짜는 연구의 존재를 보여 주지만 외부 시점 인증이나 그날의 연속 작업시간을 증명하지 않는다.

확인된 설계일 8월 9일부터 종료일 10월 27일까지 날짜 차이는 79일이며 양 끝 날짜를 세면 80개 날짜다. 이 사이에 매일 작업했다거나 8월과 10월 사이에는 아무 작업도 없었다고 추정하지 않는다.9월 보고서 복구 요청은 중간 활동의 단서이며, 해당 대화 전체의 실행 상태는 미확인이다. 그림은 날짜의 실제 간격을 유지해 긴 공백을 숨기지 않았다.

초기 설계부터 동결까지: 문서상79일에 걸친 기록



그림 1. 기록이 있는 주요 시점. 선은 시간축이며 지속 작업·GPU 연속 가동을 뜻하지 않는다.

날짜	단계	실제 작업	증거
2026-08-09	초기 설계 고정	S3a/S3b·matched·사람 교정 분리, 첫 Git 커밋	Git·설계 문서 직접 확인
2026-08-14	교사 파일럿	GPT-OSS-20B 50응답, 계획60 중10미수집	당시 보고서·보존 도구 출력
2026-08-15	Pilot 학습·새 평가	PASS30 → EXAONE15단계 → 신규20문항8대12	보존 도구 출력·문서
2026-09-16	보고서 복구 요청	웹 프로젝트에 이전 보고서를 찾는 요청	WebGPT가 읽은 프로젝트 발췌; 전후 작업량 미확인
2026-10-22	클라우드 전환	DGX 접근 일정 불확실, 기존 코드 보존·실행부 재설계	수정계획서·로컬 기록
2026-10-23	임대 A40 파일럿	실제 교사 설정·학생 로딩과 학습 경로 확인	실행 로그
2026-10-24	24GB로 이어 수집	A5000에서 비용 절감, 회수·실패 상태 분리	수집·백업 기록
2026-10-25	원래 본학습	같은 기반 모델에서 학생10개 독립 학습	run metadata
2026-10-26	평가·수학 보완	13조건 비교, 후속 보완 후보 미승격	평가·학습 기록
2026-10-27	확인·개선·동결	신규 확인720응답, A4/B4/C5, 마지막R6 후 종료	공개 원자료·동결 기록

근거: Git 기록·계획서·당시 보고서·실행 로그·웹 프로젝트의 대조 · 공개 데이터 키: synthesis-timeline

07. 사용자·웹 ChatGPT·Codex의 역할

사용자는 연구의 목표와 학교 과제 맥락을 제시하고 예산, 장비 사용, 추가 실험 여부, 마감과 공개 범위를 결정했다. 웹 ChatGPT는 초기·중기 설계와 문서 정리에서 중요한 협업 상대였고, 후기에는 해석 자문과 제한된 AI 쌍대판정에도 참여했다. Codex는 실행 가능한 코드, 실험 운영, 로그 대조, 통계와 산출물 작성에 관여했다.

사용자가 기억하는 최근 집중 협업은 10월 23일 금요일 이후의 임대 GPU 작업이다. 실제 기록에는 10월 22일 준비와 8월 15일의 Codex 실행·분석 보조도 남아 있다. 이를 지우고 'Codex는 금요일에 처음 참여했다'고 쓰거나, 웹 ChatGPT가 원격 GPU를 직접 운영했다고 쓰지 않는다. AI가 제안·구현·검수한 부분을 사용자 혼자 수작업으로 수행한 것으로 확대하지 않는다.

주체	확인되는 역할	해석의 범위
연구자(사용자)	연구 질문·학교 탐구 맥락, 예산·장비·계속/중단 결정, 결과 검토와 최종 공개 요청	직접 검수 완료 건수나 노동시간은 별도 기록 없이는 단정하지 않음
웹 ChatGPT	초기·중기 연구 설계와 문서 정리, 후반 방법론 자문 및 일부 블라인드 AI 판정, 이번 역사 자료 검토	원격 GPU를 직접 운영한 주체로 쓰지 않음
Codex	8월 실행·분석 보조;10월 코드·임대 GPU·수집·학습·평가·백업·통계·공개 보고서	참여가10월23일에 처음 시작됐다고 단정하지 않음
사람 독립 검수	실제 완료가 문항별로 입증된 검수자0명	AI 판정·사용자 비공식 검토·검수 도구 마련을 사람2명 검수로 대체하지 않음

근거: 사용자의 역할 회고,8월·10월 Codex 로그,WebGPT 문서 조사 · 공개 데이터 키: synthesis-roles

08. 계획을 그대로 따르지 않고 바꾼 사항

계획 변경은 이 연구의 실제 역사다. 초기에는 DGX Spark와 GPT-OSS-120B·GLM-4.5-Air를 중심으로 구상했으나,10월 22일 수정안은 학교 장비 접근과 일정이 확정되지 않아 이를 본실험 필수 자원에서 제외했다. 특정 하드웨어 고장이나 DGX 성능 부족을 전환 원인으로 보탤 근거는 없다.

수정안조차 실제 실행과 같지는 않았다.48GB A6000 우선 임대·로컬 학생 학습 계획은 A40 파일럿, A5000 24GB 본수집과 본학습으로 바뀌었다. 교사, 평가 범위, 검수자, 후속 학습과 중단 기준도 변했다. 변경을 숨기지 않되 계획에 적힌 모든 기능이 실행됐다는 인상을 주지 않는다.

항목	당시 계획	실제 수행	의미
주 실행 장비	DGX Spark → 수정안48GB 클라우드	A40 파일럿 후 A5000 24GB 본수집·본학습	학교 장비 접근 일정·예산에 맞춘 실제 변경
교사 모델	GPT-OSS-120B + GLM-4.5-Air	GPT-OSS-20B + GLM-4.7-Flash	대형 두 교사 실험을 완료했다고 쓰지 않음
학생 학습 장치	수정안은 로컬 RTX5060Ti	초기 Pilot·새 확인은 로컬; 본학습·후속은 임대A5000	로컬 검증과 클라우드 학습을 분리
검수 주체	사람2명의 독립 검수와 일치도	AI 검수; 일부72쌍은 두 AI; 사람0명	계획 변경·핵심 한계로 공개

항목	당시 계획	실제 수행	의미
후속 학습	5일 실험과 결과 정리	수학 보완·A4/B4/C5·마지막R6 추가	예산 승인과 중단 결정을 단계별로 기록
최종 평가	학습 전200개 이상 새 비공개 평가	원래S5 확인240실행; 후속160및 R6 200은 봉인 후 미실행	각 세대의 실행 여부와 공개80 보조를 구분

근거: 초기·수정 DOCX,실행 이력,사용자의 변경 지시 · 공개 데이터 키: synthesis-changes

09. 8월 9일에 정리된 비교 통제와 데이터 계약

초기 설계 감사에서 S3에 질문당 두 교사 답을 모두 넣고 S4에 한 답만 넣으면, 검증 유무와 데이터량·교사 비율·답 길이가 함께 달라진다는 문제가 드러났다.8월 9일 설계 문서는 S3a와 S3b를 분리하고, S4_teacher_only와 같은 질문 집합을 갖는 S3_matched를 만들도록 정리했다. 이 변경을 파일럿 결과를 본 뒤 뒤늦게 추가한 것으로 서술하지 않는다.

또한 사람이 정답을 새로 써 주는 경우에는 교사 답 검증과 사람 지식 제공이 섞이므로 teacher-only와 human-corrected를 분리했다. 한국어 원천 자료가 아직 없는 S5는 빈 placeholder로 두었고, S4 복사본을 S5 실험으로 표시하지 않았다. 이후 실제 자료가 마련된 10월 조건과 8월의 미실행 확장 계획은 같은 이름이라도 다른 상태이다.

실제 10월 matched 비교에서는 7779개 질문의 ID·개수·영역과 문항별 감독 토큰 예산을 맞췄다. 답 후반의 손실 마스킹은 감독량 통제이지만 정답의 내용·토큰 위치를 완전히 같게 만들지는 않는다. 이 잔여 차이까지 없앴다고 주장하지 않는다.

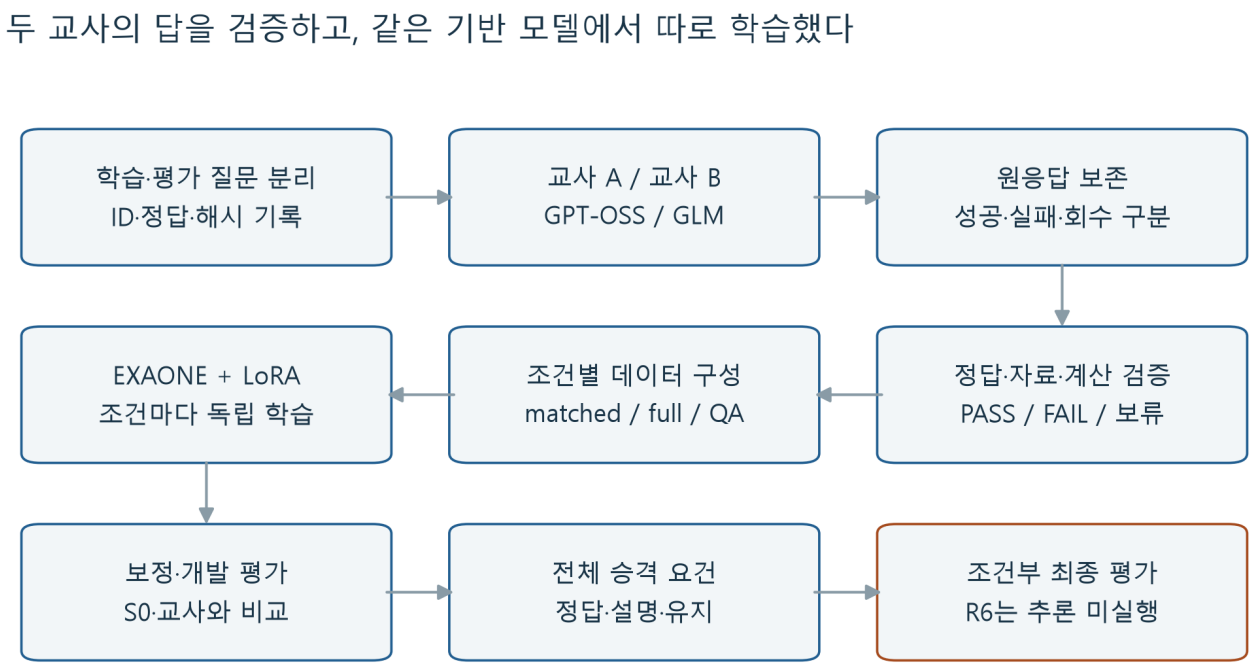


그림 2. 교사 응답·검증·독립 학생 학습·평가를 연결한 실제 연구 구조. S0는 별도 기준선이다.

조건	입력 자료	목적
S0	추가 학습 없음	고정 EXAONE 기반 기준선
S1 / S2	각 교사의 원답변7779개	같은 질문에서 단일 교사 차이
S3_matched	질문당 한 교사,품질 신호 없이7779개	S4와 질문·표본·영역 및 감독 토큰 예산 통제
S3a	검증 전 전체20104응답	두 교사 전체 자료. 자료량 차이 동반
S4_teacher_only	검증된 교사 답7779개	matched 주 비교; 사람 새 답 제외
S4_full_verified	검증 통과 전체14903응답	전체 검증본의 실용 조건
S5 / S5_general_control	검증본+한국어500 / 영어 일반 QA500	각15403행. 서로 다른 확장·대조 조건

근거: 8월 설계 결정과10월 실제 동결 데이터 · 공개 데이터 키: synthesis-conditions

10. 8월 교사 파일럿: 계획 60문항과 분석 50응답

당시 보고서는 8월 14일 512토큰 한도의 교사 실행에서 49개 성공과 11개 최종 내용 공백 오류를 기록한다. 이후 1536토큰의 별도 실행을 만들었고, 최종 파일럿 분석은 그 실행의 50응답에 한정했다. 두 실행을 합쳐 하나의 성공 실적으로 세지 않았다. 계획 60문항 중 10문항은 해당 분석 실행에서 미수집이다.

실제 완료된 교사는 GPT-OSS-20B 하나였다. GPT-OSS-120B와 GLM-4.5-Air의 다중 교사 본실험을 이 파일럿으로 대체해 완료 처리할 수 없다. 'DGX용 실행 경로에서 수집'이라는 기록은 있지만 보존 메타데이터의 엔진·양자화·리비전·장비 항목이 비어 있어 당시 하드웨어 전체를 독립 복원할 수 없다.

50응답은 PASS 30·FAIL 20으로 정리됐다. 검토 유형명 interactive_manual_review 또는 independent_source_review가 있다고 해서 실제 사람 두 명의 독립 판정이 입증되는 것은 아니다. 본 연구는 검수 유형, 도구 기능, 실제 완료된 검수자를 분리해 기록한다.

근거: 8월15일 기록된 신규20문항 파일럿 · 공개 데이터 키: synthesis-pilot

11. PASS 30개로 실제 학생 어댑터를 만들다

학습에는 검토를 통과한 30개만 사용했다. FAIL·모의 응답·비공개 평가를 섞지 않았고, 양자화가 불가능할 때 비양자화 실행으로 바꾸어 성공한 것으로 처리하지 않았다. EXAONE-3.5-7.8B-Instruct의 고정 리비전을 RTX5060Ti에서 4비트 NF4와 BF16 계산으로 불러와 LoRA를 학습했다.

설정은 rank16, alpha32, dropout0.05, q/k/v/out 투영, 배치 1·누적 4, 최대길이 768, 학습률 2e-4, 최대 15스텝이었다. 설정상 2epoch였지만 실제 마지막 epoch는 1.9333, 학습기 runtime은 428.9092초였다. 저장·재로딩을 확인한 실제 어댑터가 남았다는 것이 이 단계의 공학적 성과다.

30개 학습 예제와 15번 업데이트만으로 범용 지능을 높였다고 말할 수는 없다. 이 단계는 작은 검증 자료를 실제 모델에 연결하고, 메모리·학습·저장·재로딩·평가 경로를 완성한 파일럿으로 평가한다.

근거: 8월15일 기록된 신규20문항 파일럿 · 공개 데이터 키: synthesis-pilot

12. 첫 평가의 노출 문제를 차단하고 새 20문항으로 확인하다

처음에는 남은 10문항을 미노출 평가로 쓰려 했지만 4문항에서 과거 응답 이력이 발견되어 해당 경로를 차단했다. 이후 새로운 20문항을 봉인한 다음 추론했다. 이 수정은 평가를 끝내는 것보다 미노출 조건을 확인하는 일이 먼저였음을 보여 준다. 당시 상세 시각은 보존 보고서에 기록돼 있으며 외부 시점 인증은 아니다.

기본 모델 8/20(40%)와 Pilot12/20(60%)의 차이는 20%p다. 같은 문항에서 Pilot만 맞힌 4개, 기본만 맞힌 0개, 둘 다 맞힌 8개, 둘 다 틀린 8개였고 정확 McNemar p=.125였다. 작은 표본에서 관측 증가가 있었으나 통계적 우월성을 확인한 결과로 보고하지 않는다.

개선 4개에는 출력 형식, 잘림 회피, 코드 검사 규약 적합성 등이 섞여 있었다. 초기부터 의미 정확도와 출력 규약을 분리해야 할 이유가 있었으며, 이 관찰을 훗날 수학 저하의 원인을 이미 입증한 실험으로 과장하지 않는다.

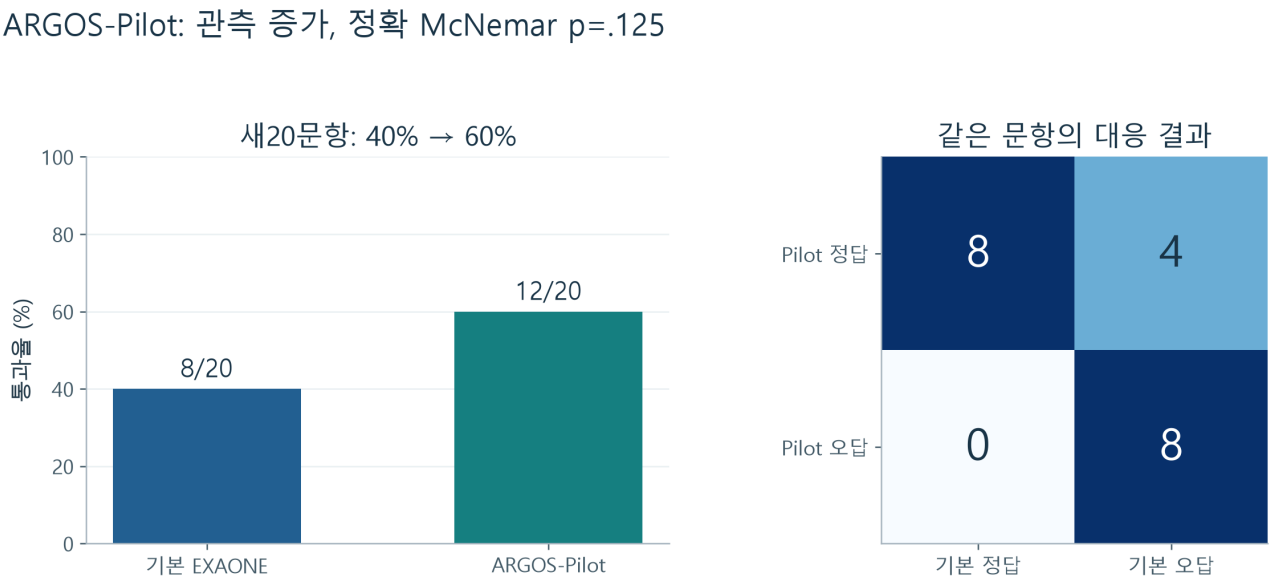


그림 3. 신규 20문항의 대응 결과.20%p 차이는 관측값이며 정확 McNemar p=.125이다.

모델	정답	문항
기본 EXAONE	8	20
ARGOS-Pilot	12	20

근거: 8월15일 기록된 신규20문항 파일럿 · 공개 데이터 키: synthesis-pilot

13. 문서를 보존하고 클라우드 실행부를 다시 설계하다

9월 16일 웹 프로젝트의 '자유보고서 복구' 발췌에는 이전 보고서를 찾는 사용자 요청이 남아 있다. 이는 초기 문서 작업이 존재했음을 뒷받침하지만 복구 완료나 그날 전체 연구 재개를 증명하지는 않는다.8월과 10월 사이의 모든 작업을 복원할 수 없으므로 공백의 이유와 노동시간을 추정하지 않았다.

10월 전환에서는 기존 핵심 코드와 데이터를 보존하고, 장시간 수집·재시도·저장·중단 후 재개·백업을 담당하는 실행부를 다시 구성했다. 웹 GPT가 확인한 준비 보고서는 기존 154개 자료·평가 파일 해시 보존과 원

본 소스 보관, 기존 79개와 신규 26개를 합친 105개 CPU 시험을 기록한다. 이는 당시 준비 문서의 증거이며 이번에 같은 시험을 다시 실행한 수치가 아니다.

모의 서버 240응답, SQLite 작업 20000개의 종료·재개 시험, tiny LoRA CPU2스텝은 소프트웨어 경로 검증이다. 실제 대형 교사 응답 수,2만 개 고품질 정답,72시간 무인 운영 또는 EXAONE GPU 성능으로 합산하지 않는다. 이 구분을 거친 뒤에 실제 임대 장비에서 파일럿을 수행했다.

근거: Git 기록·계획서·당시 보고서·실행 로그·웹 프로젝트의 대조 · 공개 데이터 키: synthesis-timeline

14. 실제 A40 임대에서 드러난 저장 공간·추론 설정 문제

우선 후보였던 A6000은 실제 본문에서 사용한 장비가 아니다. 보존 기록상 실제 초기 임대는 A40이며 관측 VRAM은 46068MiB였다. 당시 GPU 단가 0.59달러/시간과 디스크를 합친 관측 요율은 약 0.598달러/시간이었다. 이는 당시 기록이며 현재 서비스 가격으로 제시하지 않는다.

초기에는 학생 FP32 캐시 약 31.27GB와 두 교사 GGUF 약 29.94GB가 50GB 루트 공간을 함께 압박했다. 모델이 메모리에 들어가는지뿐 아니라 다운로드·캐시·저장본을 보관할 디스크 예산도 필요했다. 저장 경로 정비 뒤 32개 fixture로 EXAONE2스텝 학습을 실행했다.75.0468초의 학습과 115.097초의 로딩·저장·재로딩 관측은 동작 확인이며 성능 향상 평가가 아니다.

교사 설정 탐색에는 150개 고유 질문에 여러 설정으로 생성한 758개 완료 응답이 기록됐다. 선택 프로파일의 자동 PASS는 GPT108/150, GLM114/150였고 검토 필요 31개씩을 별도로 남겼다. GLM의 thinking을 끈 설정은 빨랐지만 73개 오답이 관측돼 채택하지 않았다. 빠른 처리량과 답의 적합성을 함께 보았던 단계다.

근거: Git 기록·계획서·당시 보고서·실행 로그·웹 프로젝트의 대조 · 공개 데이터 키: synthesis-timeline

III. 임대 GPU에서 만든 원래 ARGOS

15. 48GB에서 24GB로 옮긴 실제 이유와 실행 범위

A40 단계는 시간·비용 경계에서 중지했다. 중지 당시 로컬에는 3936개만 보였지만 원격 성공 7480개를 회수해 확인했고, 남은 12500개는 대기·20개는 실패로 구분했다. 중단 자체가 기존 성공을 없애는 것은 아니지만, 회수하지 않은 응답을 학습 가능 데이터로 계산할 수도 없었다.

이후 임대한 A5000은 관측 24564MiB의 24GB급 GPU였다. 당시 GPU 표기 요율 0.27달러/시간, 보수적 예산 계산 0.31달러/시간을 사용했다. 교사는 양자화 GGUF와 llama.cpp로 순차 적재했고, 학생 본학습도 이 임대 장치에서 수행했다. 원래 수정안의 '교사 클라우드·학생 로컬'과 다른 실제 실행이다.

이전과 같은 질문·교사 설정을 이어 사용했지만 환경이 같다고 출력 문자열까지 완전히 같지는 않았다. 로컬·클라우드의 100개 대응 응답 중 36개는 문자열이 같고 64개는 달랐다. 이 일치율은 정확도 비교도, VRAM 변화가 차이의 유일한 원인이라는 실험도 아니다.

근거: 이전 보고서의 수집 원장·제외 원장·학습 자료 분석 · 공개 데이터 키: historical-collection

16. 응답 생성·회수·제외·검증을 맞춘 데이터 장부

본수집의 원격 성공 19923개와 생성 실패 77개는 작업 상태다. 실제 로컬에 회수된 본수집 성공은 19839개였으므로 성공 84개가 회수되지 않았다. 이 84개는 실패 77개와 다르며 학습 입력에 포함하지 않았다. 정치·역사·국제관계의 교사 차이를 살펴보기 위한 보충은 144질문×두 교사 288개를 목표로 했고 287개가 저장됐다. 남은 GPT 응답 1개는 세 번 시도 후에도 길이 실패로 남겼다.

로컬 본수집 19839와 보충 287을 더한 20126응답 중 11질문·22응답은 동결 전에 제외했다.10개 의견형 질문과 잠재 평가 겹침이 있는 1개 질문으로, 단순 중복 제거 22개라고 부르지 않는다. 이후 원본 전체 조건은 20104응답·10133질문, 검증 통과는 14903응답·7974질문이었다. 검증 실패 1228과 추가 검토 보류 3973을 더하면 원본 20104가 된다.

보충의 초기 로컬 101응답과 같은 질문의 클라우드 재실행은 원본을 보존한 별도 계보다. 같은 질문을 두 번 생성했다고 신규 고유 질문으로 두 번 세지 않았다. 이 장부는 데이터가 '있다'는 주장보다 실제 학습 가능한 상태와 회수 여부를 더 정확히 설명한다.

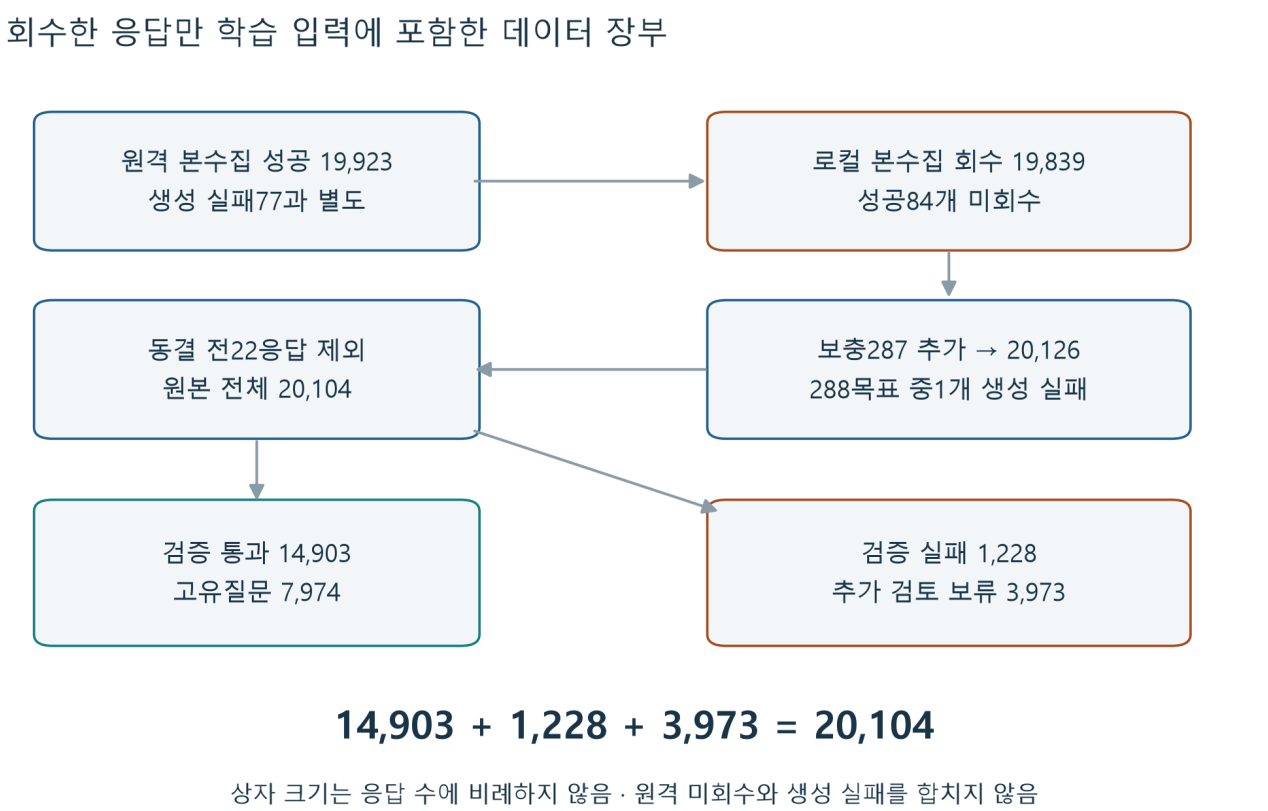


그림 4. 서로 다른 상태를 분리한 응답 회계. 원격 미회수 84와 생성 실패 77은 별개다.

단계	응답 수	정의
원격 본수집 성공	19,923	생성 실패77개와 구분
로컬 본수집 회수	19,839	성공했으나 회수되지 않은84개는 학습 입력에 포함하지 않음
보충 로컬 성공	287	144질문·두 교사에서1개 생성 실패
로컬 통합 입력	20,126	19,839+287

단계	응답 수	정의
동결 전 제외	22	의견·잠재 평가 겹침11질문; 중복 제거가 아님
원본 전체 학습 조건	20,104	고유10,133질문
검증본	14,903	고유7,974질문; 검증 실패1,228·추가 검토 보류3,973 제외
최종 선택 모델 학습	15,403	검증14,903+일반 QA500; S5_general_control

근거: 이전 보고서의 수집 원장·제외 원장·학습 자료 분석 · 공개 데이터 키: historical-collection

17. 검증 통과 데이터도 학습에 필요한 정보를 잃을 수 있다

검증은 정답표·계산·제공 자료·외부 근거 등으로 응답을 분류하는 절차다. 두 교사가 동의했다는 이유만으로 사실이라고 정하지 않았으며 미확정 응답은 보류했다. 다만 자동 판정과 단일 AI 검수에 의존한 범위가 커서 14,903개를 독립 사람 두 명이 검토한 고품질 정답으로 표현할 수 없다.

중요한 진단은 최종 학습 대상이 교사의 모든 설명 원문과 같지 않다는 점이었다. 원본 전체 S3a의 평균 목표 답 길이와 검증본의 길이가 달랐고, matched 조건의 평균 감독 토큰은 약 3.95개였다. 정답을 짧게 추출한 자료와 토큰 예산 마스킹은 형식 학습에는 유리할 수 있지만 풀이 과정을 충분히 제공하지 못할 가능성이 있다.

이것은 수학 손실의 유력한 해석 단서이며 확정 원인은 아니다. 원본 전체와 검증본 전체는 질문 구성도 다르고, 필터링·문장 가공·학습률·감독 길이가 함께 변했다. 따라서 '검증 때문에 수학이 망가졌다'거나 '짧은 답만이 원인이다'라는 단일 원인 결론을 내리지 않는다.

근거: 8월 설계 결정과10월 실제 동결 데이터 · 공개 데이터 키: synthesis-conditions

18. 열 개의 학생 학습은 독립된 비교 실험이었다

각 조건은 같은 고정 EXAONE 기반 모델에서 독립적으로 시작했다. S3_matched와 S4_teacher_only는 두 시드로 실행하고 나머지는 한 시드로 실행하여 총 10개 학생 어댑터를 만들었다. 한 모델에 10차례 누적 학습하거나 서로 다른 어댑터를 병합한 과정이 아니다. 표의 seed 날짜처럼 보이는 숫자는 시드·variant 표기이며 실제 실행 날짜와 자동으로 같지 않다.

원래 S5_general_control은 검증 14903개와 일반 영어 QA500개, 총 15403개를 한 번 순회해 963단계를 학습했다. 한국어 QA500개를 추가한 S5와 별도 조건이다. LoRA r16·alpha32·dropout0.05, 학습률 2e-4,4비트 학습과 저장·재로딩 기록이 보존돼 있다.10개 학습기의 runtime 합계는 약 6.03시간이며 교사 수집·다운로드·평가·대기 시간을 포함한 전체 임대 시간은 아니다.

LoRA는 기반 가중치를 고정하고 작은 저랭크 행렬을 학습하는 방법이며, QLoRA는 양자화한 기반 모델을 통해 어댑터를 학습해 메모리 부담을 줄이는 방법이다. 본 연구의 정확한 모듈·양자화·학습률은 실행 설정으로 확인했다. 방법 자체의 선행 성과를 ARGOS의 성과로 대신 인용하지 않는다. LoRA, QLoRA.

학습본	행	단계	학습 분	시드	재로딩
S1	7779	487	23.56	20261022	확인

학습본	행	단계	학습 분	시드	재로딩
S2	7779	487	23.35	20261022	확인
S3 matched · s22	7779	487	25.62	20261022	확인
S3 matched · s23	7779	487	25.8	20261023	확인
S3a	20104	1257	66.15	20261022	확인
S4 full	14903	932	45.29	20261022	확인
S4 only · s22	7779	487	27.58	20261022	확인
S4 only · s23	7779	487	23.71	20261023	확인
S5 한국어	15403	963	53.03	20261022	확인
ARGOS S5 general	15403	963	47.88	20261022	확인

근거: 원래 10개 run_metadata / training logs의 보존 집계 · 공개 데이터 키: synthesis-original-training

19. 13개 조건에서 의미 정확도와 형식 통과가 갈라졌다

원래 확장 평가의 비공개 240문항에서 S5_general_control은 의미 정답 102개, 지시 준수 213개, 동시 통과 96개였다. 기본 S0는 각각 143·82·63개였다. 내용과 형식을 함께 요구한 점수는 높아졌지만 내용 정답 수 자체는 줄었다. GPT-OSS와 GLM의 의미 정답은 189·218개, 동시 통과는 177·206개로 대표 학생보다 높았다.

대표 체크포인트는 완료된 결과를 본 뒤 실용적으로 선정했다. 기존 ORIGINAL의 99/240, EXTENDED8192의 96/240은 관측 학생 중 높은 동시 통과였지만 두 설정은 같은 핵심 문항을 재사용했다. 독립 반복이나 범용 최우수성의 증거가 아니다. 공개 KMMLU100문항 등은 별도 보조 평가로 유지한다.

원래 주 비교인 S4_teacher_only-S3_matched의 두 시드 평균 동시 통과 차이는 ORIGINAL -1.25%p, EXTENDED8192 약-0.21%p였다. 문항·유형 재표집 95%구간은 모두 0을 포함했다. 이번 통제에서 검증본의 확정적 우위를 확인하지 못했으며, 이것이 두 방법의 동등성 또는 모든 지표에서 검증의 무용성을 증명하지는 않는다.

원래 본실험13조건: 형식 통과 증가와 의미 정답 감소를 구분

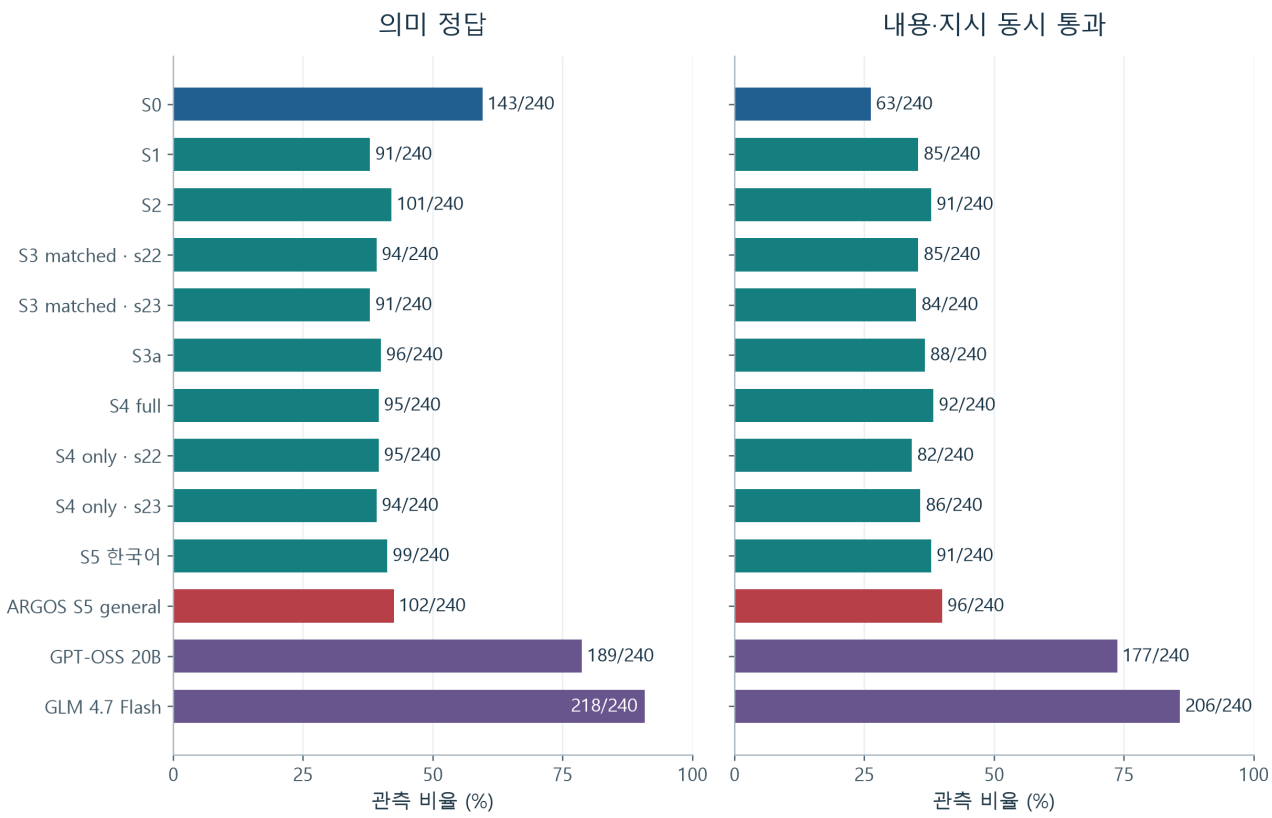


그림 5. 기존 확장 240문항의 13조건 비교. 모델 선정에도 사용된 관측값이며 독립 확인 성적이 아니다.

조건	의미 /240	지시 /240	동시 /240
S0	143	82	63
S1	91	216	85
S2	101	206	91
S3 matched · s22	94	212	85
S3 matched · s23	91	220	84
S3a	96	220	88
S4 full	95	212	92
S4 only · s22	95	197	82
S4 only · s23	94	213	86
S5 한국어	99	214	91
ARGOS S5 general	102	213	96
GPT-OSS 20B	189	217	177
GLM 4.7 Flash	218	220	206

근거: 원래 본실험 historical_metrics.json: extended_8192 / private / 240문항 · 공개 데이터 키: synthesis-original-models

20. 일부 표본에서는 교사를 앞섰다는 관측도 보존한다

기존 정치·역사 40문항에서 대표 S5는 37개, GPT-OSS는 31개, GLM은 36개를 맞혔다. 원문 재검사 124문항에서는 S5 87개, GPT59개, GLM80개였다. 이 표본의 의미 정답 수에서 두 교사보다 높은 관측값이 있었다는 사실을 숨기지 않는다. 원문 재검사에서는 S4 full이 90개로 대표 S5보다 더 높았으며 대표 선정은 모든 세부 지표의 최고값을 뜻하지 않았다.

반면 새 민감 36문항에서는 S5 15개, GPT12개, GLM22개로 두 교사를 함께 앞서지 못했다. 표본마다 선정·노출·용도가 다르며, 교사 불일치를 찾아 만든 자료와 기존 진단 자료에는 선택 편향이 있을 수 있다. 기존 정치·역사 40문항도 진단과 선택에 활용됐다.

따라서 '일부에서라도 앞선 적이 없었는가'에는 관측상 앞선 지표가 있었다고 답할 수 있다. 그러나 계획이 요구한 새 비공개 영역·기반 모델 향상·반복 검증까지 갖춘 '입증된 부분 초월'로 승격할 증거는 부족하다. 관측된 성과와 검증 강도를 한 문장 안에서 함께 제시하는 것이 정확하다.

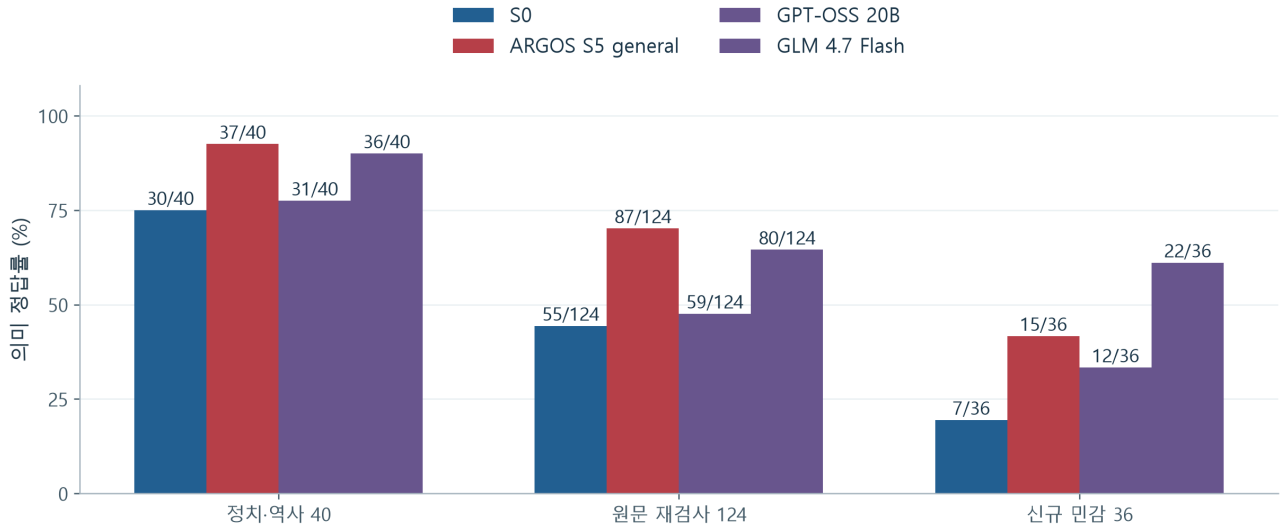


그림 6. 교사보다 앞선 표본과 앞서지 못한 표본을 함께 표시한다. 서로 다른 표본의 비율을 하나의 종합점수로 합치지 않는다.

표본	모델	정답	문항
정치·역사 40	S0	30	40
정치·역사 40	ARGOS S5 general	37	40
정치·역사 40	GPT-OSS 20B	31	40
정치·역사 40	GLM 4.7 Flash	36	40
원문 재검사 124	S0	55	124
원문 재검사 124	ARGOS S5 general	87	124
원문 재검사 124	GPT-OSS 20B	59	124
원문 재검사 124	GLM 4.7 Flash	80	124

표본	모델	정답	문항
신규 민감 36	S0	7	36
신규 민감 36	ARGOS S5 general	15	36
신규 민감 36	GPT-OSS 20B	12	36
신규 민감 36	GLM 4.7 Flash	22	36

근거: 기존 정치·역사40, source124, new36 실측 집계 · 공개 데이터 키: synthesis-specialized

21. 동결 S5의 새 240문항과 공개 120문항은 실제 실행했다

원래 S5를 동결한 뒤 새 합성 240문항과 공개 보조 120문항에 S0·S5를 실행해 720응답을 얻었다. 새 수학 80, 제공 자료 60, 전제 60, 정확 출력 40과 GSM8K·KLUE-NLI·KoBEST 각 40개다. 로컬 RTX5060Ti8GB에서 NF4·BF16,224개 양자화 모듈을 확인했으며 추가 학습 없이 실행했다.

자료 결론 정답은 S0 53/60에서 S5 60/60, 정확 출력은 3/40에서 27/40으로 늘었다. 반면 새 수학은 68/80에서 37/80, GSM8K는 37/40에서 6/40으로 줄었다. 전제 결론도 55/60에서 50/60이었다. 한국어 보조 점수의 작은 차이를 모든 한국어 능력 향상으로 확대하지 않는다.

문항·모델·생성 상한은 앞서 고정했지만 상세 형식 채점의 운영 규칙 일부는 출력이 나온 뒤 모델 신원 공개 전에 확정했다. 외부 사전등록이나 독립 사람 확증 시험이라고 부르지 않는다. 이 실행은 이후 R6의 미실행 최종 평가와 별개이며, 프로젝트가 최종 성격의 새 평가를 전혀 하지 않았다고 쓰는 것도 틀리다.

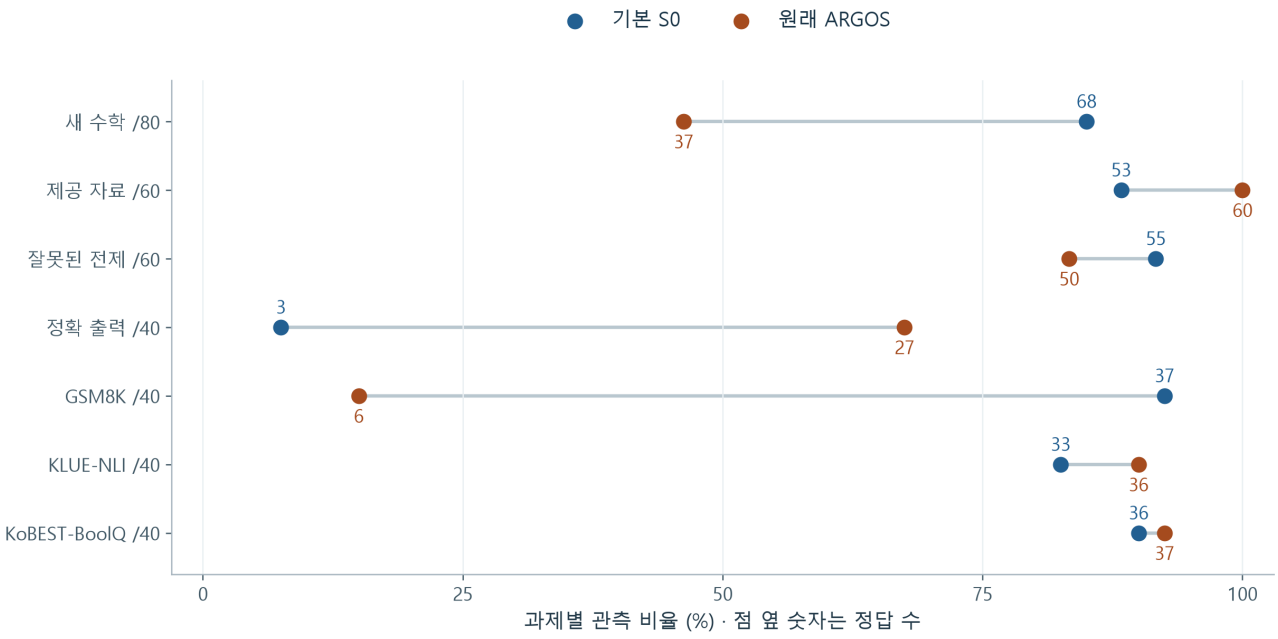


그림 7. 동결된 원래 S5의 새 평가. 차이는 ARGOS-S0이며 과제별 분모와 점수 정의가 다르다.

과제	문항	기본	원래ARGOS	차이 %p
새 수학	80	68	37	-38.75

과제	문항	기본	원래ARGOS	차이 %p
제공 자료	60	53	60	11.67
잘못된 전제	60	55	50	-8.33
정확 출력	40	3	27	60.0
GSM8K	40	37	6	-77.5
KLUE-NLI	40	33	36	7.5
KoBEST-BoolQ	40	36	37	2.5

근거: 동결된 원래 S5의 신규 확인: 비공개240 + 공개120, 총720응답 · 공개 데이터 키: synthesis-confirmation

22. 409개 주장과 40쌍의 보조 검수는 다른 성과를 보여 줬다

제공 자료 60응답씩에서 분해한 주장은 S0 228개, ARGOS181개로 총 409개였다. S0는 자료 지지 176·모순 0·뒷받침되지 않음 49·미확정 3개, ARGOS는 지지 181개였다. 요구 사실 180개 중 지지한 수는 173개와 180개였다. 이 표본에서 ARGOS가 불필요한 추가 주장을 줄이고 필요한 사실을 포함했다는 관측이다.

이 수치를 '환각률 0'이나 개방형 사실 지식의 완전성으로 바꾸면 안 된다. 제공한 가상 기록에 대한 단일 AI 판정이고, 자료에 없는 주장은 거짓이 확인된 모순과도 다르다. 이후 798개 주장 분석은 다른 문서·모델 집합을 사용하므로 두 수치를 같은 집단의 전후 오류율로 연결하지 않는다.

자료 20쌍·전제 20쌍을 합친 단일 AI 익명 선호는 S0 20승, ARGOS6승, 동률 14쌍이었다. 결론을 맞히는 능력, 필요한 설명을 제공하는 능력, 답이 간결한 정도는 같은 지표가 아니다. 사람이 평가한 선호나 평가자 간 일치도로 보고하지 않는다.

모델	주장	지지	모순	근거 없음	미확정
S0	228	176	0	49	3
ARGOS	181	181	0	0	0

근거: 원래 신규 확인의 제공 자료60문항×2모델,409개 주장 · 공개 데이터 키: synthesis-original-claims

IV. 손실을 확인하고 개선을 시도한 과정

23. 수학이 낮아진 현상을 원인과 구분해 진단하다

수학 저하는 새 확인에서 처음 발견된 예상 밖의 현상이 아니었다. 기존 확장 STEM100문항에서 대표 S5는 1개, 기본 S0는 50개를 맞혔고 이 약점은 대표 선정 기록에도 적혀 있었다. 짧은 정답을 내는 양상, 설명형 목표의 감소, 형식 점수의 증가가 함께 나타났다.

먼저 실행 오류를 의심하고 기반 모델·어댑터 비활성화·토크나이저·정밀도·생성 지시를 점검했다. 노출된 수학 16문항 재실행은 이전과현재 모두 14개 정답이었으나 승패가 바뀐 두 문항이 있었다. 쉬운 4문항과 어댑터 비활성화의 일부 출력 일치는 광범위한 런타임 붕괴에 반하는 작은 통제이지만 완전한 환경 동등성의 증명은 아니다.

자료 필터링과 목표 길이, 학습률·손실 마스킹·선정 정책이 함께 바뀌었으므로 하나의 요소에 원인을 확정할 수 없다. 이후 실험은 진단 단서를 바탕으로 목표 설명·수학 유지 자료·학습 강도를 바꾸되, 실제 기준선보다 나아졌는지를 다시 확인하는 방향으로 진행했다.

근거: 기존 노출140문항(STEM100·정치역사40)의 동결된 비교 · 공개 데이터 키: synthesis-followup-140

24. 기존 140문항을 활용한 앞선 보완과 승격 실패

10월 26일에는 원래 교사로 수학 자료를 다시 수집하고 형식·풀이를 보완한 학습을 시도했다. 수학 관련 네 개 저장본과 일반 보충 한 개 저장본의 기록이 남아 있다. 네 체크포인트를 네 개 독립 학습으로 세지 않으며, 원래 대표 S5를 새로 승격한 것으로 표시하지 않는다.

이 단계의 STEM100·정치역사 40은 이미 진단과 선정에 노출된 자료였다. 검사를 더 실행한다고 독립 새 최종셋이 되지 않는다. 수학 회복과 기존 강점 유지 조건을 함께 만족한 후보가 없어 동결된 대표 모델을 바꾸지 않았다. 이후 새 확인과 별도 개발·최종 분리가 필요해진 배경이다.

실패한 시도도 어떤 자료를 바꾸고 어떤 조건에서 멈췄는지 남겨야 한다. 본문은 성능이 올라간 마지막 후보만 골라 역사를 만들지 않고, 원래 저하·앞선 미승격·A4/B4/C5·R6를 구분한다.

모델	기존 표본	문항	의미 정답	동시 통과
S0-20261022	STEM100	100	50	0
S0-20261022	정치·역사40	40	30	26
S5_general_control-20261022	STEM100	100	1	1
S5_general_control-20261022	정치·역사40	40	37	37
glm	STEM100	100	86	82
glm	정치·역사40	40	36	36
gpt_oss	STEM100	100	72	61
gpt_oss	정치·역사40	40	31	31

근거: 기존 노출140문항(STEM100·정치역사40)의 동결된 비교 · 공개 데이터 키: synthesis-followup-140

25. 같은 이름의 평가셋들을 하나로 합치지 않는다

연구 중 '최종 평가'라는 표현은 여러 세대에 쓰였다.8월의 새 20개,10월 원래 비교, S5를 동결한 새 240+120개, A4/B4/C5의 조건부 160+80개, R6의 200+80개는 서로 다르다. 또한 개발 176개를 수차례 사용한 것은 새 176문항이 매번 생겼다는 뜻이 아니다.

이 구분은 결론을 바꾼다. 새 S5 확인은 실행됐고 수학 저하를 보여 줬다. R6의 최종 280개는 봉인했지만 실행하지 않아 점수가 없다. 이를 0점 또는 최종시험 실패로 그리지 않는다. R6의 실패는 개발 승격 조건을 만족하지 못했다는 판단이다.

새 질문 생성·정답 검증·해시 봉인은 문항 중복 위험을 줄이지만, 같은 생성 규칙의 문제 유형이 훈련·개발·최종에 반복될 수 있다. 문자 중복 0은 의미·유형의 완전한 독립성이나 사전학습 오염 부재를 증명하지 않는다.

평가 세대	구성	대상	실행 상태	용도
8월 Pilot	새20문항	S0·Pilot	실행	소규모 파일럿,8대12
10월 원래 비교	기본340 / 확장500	교사2·S0·학생10	실행·선정에도 사용	같은 핵심240 재사용; 독립 확인 아님
원래S5 신규 확인	새 합성240 + 공개120	S0·동결S5	720응답 실행	새 질문 확인; 일부 채점 운영 세부는 출력 후 확정
A4/B4/C5 개발	문서96+공개80	기준4+후보6	선정용 실행	모델별48개 보정으로 지시문 고정
A4/B4/C5 조건부 최종	새 합성160+공개80	승격 후보 예정	봉인·추론0	승격 후보 없음
R6 개발	같은 문서96+공개80	재측정S0+후보3	704응답 실행	추가 진단224와 합해928응답
R6 조건부 최종	새 합성200+이전 미사용 공개80	승격 후보 예정	봉인·추론0	최종 성능은 미측정

근거: 단계별 프로토콜·봉인·실행 영수증 · 공개 데이터 키: synthesis-evaluation-generations

26. 기본 모델과 두 교사의 기준선을 먼저 다시 세우다

A4/B4/C5 단계는 기준 모델의 실행 상태를 확인한 뒤 시작했다. 공통 보정 48문항에서 각 모델에 두 지시문 후보를 적용하고 정답 수 우선·동률이면 direct라는 규칙으로 선택했다. 답을 먼저 쓰는 방식에서 최종 결론 모순과 형식 채점 차이가 관찰되어, 개발평가 전에 근거 먼저·정답 마지막의 두 공통 후보로 바꿨다.

4096토큰 보정의 길이 종료를 확인하고 공통 상한 8192로 한 차례 확장했다. 최종 보정 384응답 중 192개는 문항·응답이 같은 기존 판정을 재사용하고 192개는 새로 읽었다. S0는 verify36/48, 기존 ARGOS는 direct17/48, GPT-OSS는 direct47/48을 기록했으며 모든 선택은 개발 결과를 보기 전에 고정했다.

이는 모델마다 동등한 선택 기회를 준 운용 비교다. 선택된 문구가 다르므로 '완전히 같은 프롬프트에서 가중치만 바꾼 실험'이라고 표현하지 않는다. 최종 답의 의미, 중간 계산, 출력 완료를 분리해 확인했다.

모델	지시문	정답	문항	선택
S0	direct	26	48	미선정
S0	verify	36	48	선정
gpt_oss	direct	47	48	선정
gpt_oss	verify	47	48	미선정
glm	direct	43	48	선정
glm	verify	39	48	미선정

모델	지시문	정답	문항	선택
ARGOS_old	direct	17	48	선정
ARGOS_old	verify	11	48	미선정

근거: 4개 모델384개 응답의 AI 의미 검수와 프롬프트 고정 · 공개 데이터 키: calibration_observed

27. 개발 176문항과 공개 정답 오류 민감도

문서 개발은 12유형에서 8개씩 96문항이다. 유지 검사는 공개 GSM8K 40문항과 KoBEST-BoolQ40문항이다. 기본 S0의 문서 정답 68·유효 설명 42·수학 35와 두 교사의 문서 93·86, 수학 38·39를 기준으로 삼았다. 문서 과제에서 두 교사와의 격차가 큰 상황임을 학습 전에 확인했다.

KoBEST의 배우와 배역 관계 1문항에서 공식 키 오류를 확인했다. 공식 점수는 유지하고 같은 수정 키를 모든 모델에 적용한 민감도 점수를 나란히 표시했다. 모델마다 유리한 키를 고르는 방식으로 수정하지 않았다. C5-152를 포함한 수정 점수의 값은 공개 채점 기록으로 재확인했다.

유효 설명은 정답을 포함하는 지표다. 정답만 맞고 계산·근거·요구 인용이 틀리면 설명은 실패한다. 이후 선정 조건에서 정답 하한보다 설명 하한이 더 엄격한 경우 그 함의도 명시했다. 다음 표는 지표별 정의를 요약한다.

지표	정의	해석 제한
의미 정답	요청한 최종 결론이 기준과 일치	긴 설명의 모든 주장이 맞다는 뜻은 아님
지시 준수·동시 통과	요구 형식 충족 / 내용과 지시 모두 충족	형식 개선이 의미 정확도 감소를 가릴 수 있음
유효 설명	정답·근거·계산·요구 인용을 기준대로 충족	정답인 응답 안에서도 설명 오류가 존재 가능
주장 단위 모순율	모순 판정 주장 수 ÷ 분해된 전체 주장 수	답 길이·주장 분해·표본 선정·평가자에 의존
쌍대 선호·자연스러움	같은 질문의 익명A/B 응답 비교	AI의 문체 선호이며 사람의 선호·정확도 대체 불가
미완료·미판정	완료·정답이 확인되지 않은 응답은 성공 분자에서 제외	전체 분모를 유지하며 미실행 평가는0점으로 대체하지 않음

근거: 고정 채점 기준과 단계별 정정 기록 · 공개 데이터 키: synthesis-metric-guide

28. A4·B4·C5: 정답만, 설명 포함, 유지 자료 혼합

A4는 600문항의 정답만을, B4는 같은 600문항의 설명과 정답을 학습했다. C5는 문서 422·실제 수학 90·일반 독해 91개의 고유 문항에 일반 자료 5개 반복을 더해 608행으로 구성했다. 고유 603개와 학습 608행을 구분한다. 일반 자료는 기존 검수 계보의 SQuAD train이며 원문 출처·고정 리비전·해시를 보존했다.

A4의 감독 토큰은 3750, B4는 29716, C5는 29869였다. B4와 C5의 감독량은 약 0.515% 차이로 맞췄지만 분포·문항·풀이 내용까지 같지는 않다. C5의 행 비율과 감독 토큰 비율을 모두 계산해 혼합량을 설명했다. 실제 토크나이저로 길이를 확인하고 1536토큰을 넘는 잘림을 허용하지 않았다.

세 조건은 모두 기존 ARGOS를 이어 학습한 것이 아니라 같은 S0에서 새로 시작했다. 설명을 추가한 효과와 기존 어댑터를 더 학습한 효과를 혼동하지 않는다. 수학과 일반 유지 자료를 넣었다는 사실만으로 보존이 보장되는지도 실제 평가로 확인했다.

조건	고유 문항	학습 행	감독 토큰	단계	최대 길이
A4	600	600	3750	150	231
B4	600	600	29716	150	306
C5	603	608	29869	152	681

근거: CPU에서 완성·검증한 학습 자료; 실행 결과와 구분 · 공개 데이터 키: training_preparation_v5

29. 세 학습·여섯 저장본과 마지막 R6까지 전체 비교

A4는 150단계, B4는 150단계, C5는 152단계로 각각 2epoch를 실행했다. 중간과 마지막 저장본을 회수·재로딩해 평가했다. 총 3회·452업데이트이며 여섯 개의 독립 재현 학습이 아니다. 손실이 유한하고 파일이 정상 저장됐다는 확인은 성능 개선의 검증과 별개다.

아래는 기준선·기존 ARGOS·A4/B4/C5 여섯 후보·R6 세 후보·두 교사를 같은 개발 항목에 놓은 13행 비교다. A4의 설명 0/96은 정답 전부가 틀렸다는 뜻이 아니라 정답만 학습한 응답이 설명 요구를 충족하지 못한 결과다. B4-075는 문서 53·수학 32로 기존 ARGOS35·6보다 높았지만 S0의 68·35보다 낮았다.

C5는 유지 자료를 섞었음에도 수학 22/40에 머물렀다. 모든 후보를 보존해 데이터 혼합의 기대가 실제 관측과 다를 수 있음을 드러낸다. 여러 후보 중 최댓값을 독립 최종 성능으로 선택하지 않았다.

모든 기준·후보의 개발 관측:13행을 빠짐없이 비교

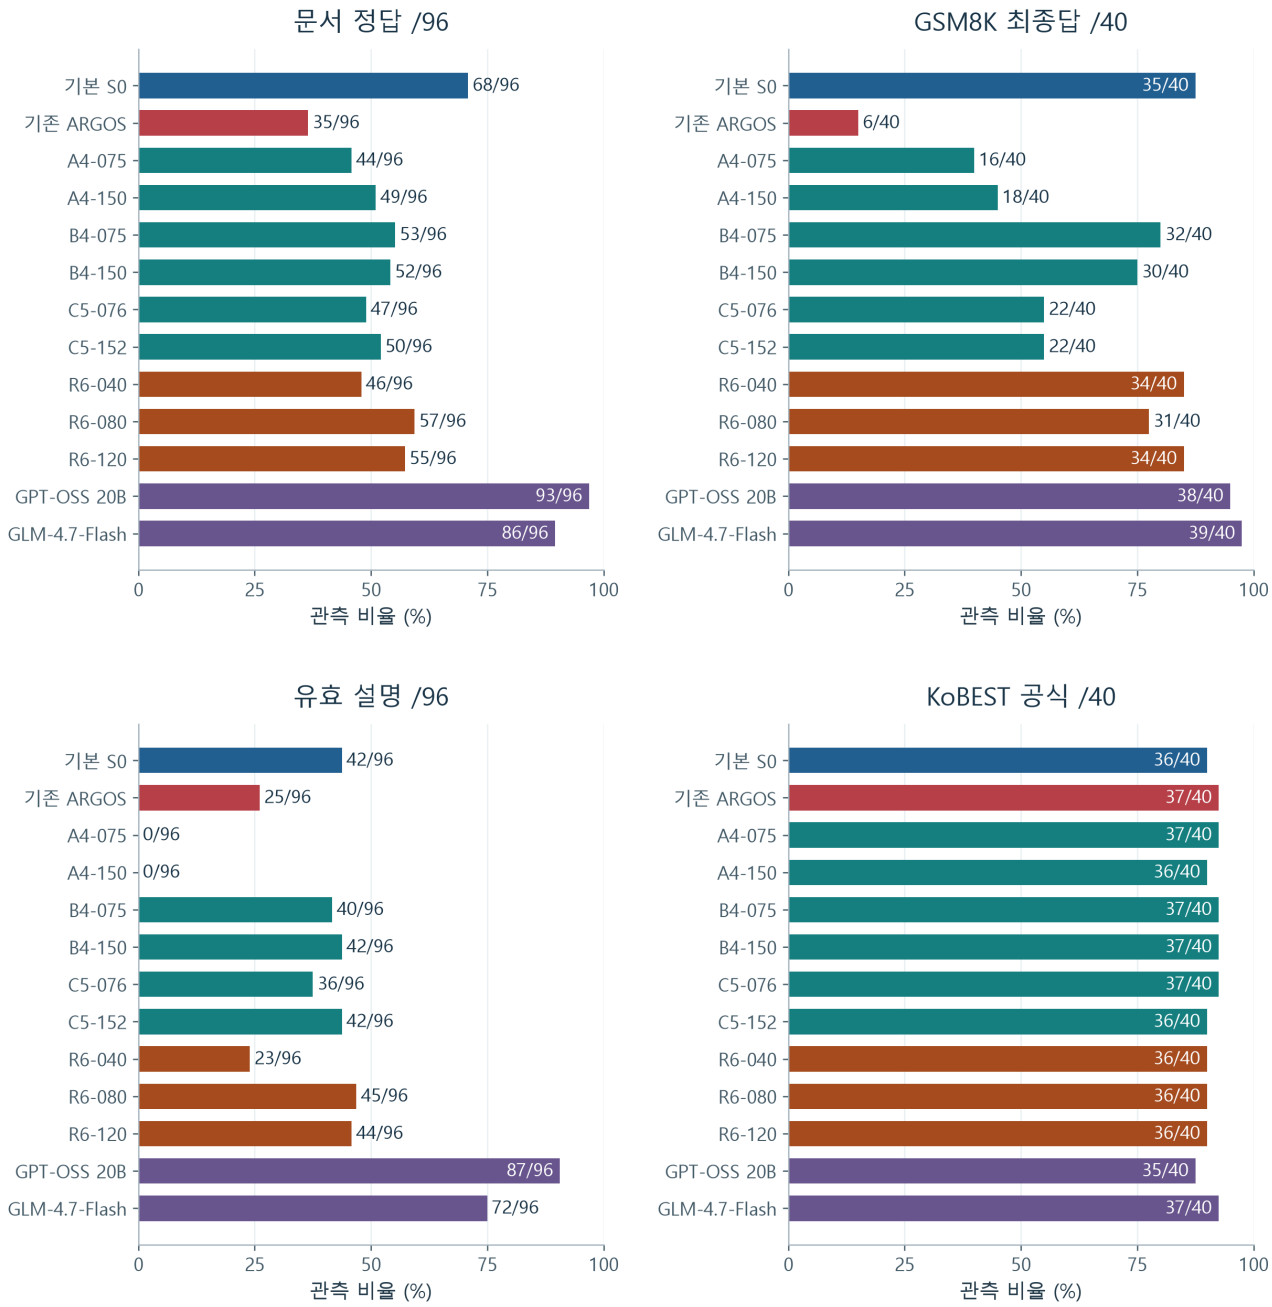


그림 8. 동일 개발 표본의 13개 모델·저장본. 모든 패널의 가로축은 0–100%이며 분모는 패널별로 표시했다. 반복 선택에 쓰인 관측이다.

모델	문서 /96	설명 /96	수학 /40	Ko /40	수정 /40
기본 S0	68	42	35	36	37
기존 ARGOS	35	25	6	37	38
A4-075	44	0	16	37	38
A4-150	49	0	18	36	37
B4-075	53	40	32	37	38

모델	문서 /96	설명 /96	수학 /40	Ko /40	수정 /40
B4-150	52	42	30	37	38
C5-076	47	36	22	37	38
C5-152	50	42	22	36	37
R6-040	46	23	34	36	37
R6-080	57	45	31	36	37
R6-120	55	44	34	36	37
GPT-OSS 20B	93	87	38	35	36
GLM-4.7-Flash	86	72	39	37	38

근거: 공개 development_metrics.csv + recovery_selection.json의 동일 개발176문항 집계 · 공개 데이터 키: synthesis-all-development

30. 후보가 좋아 보이더라도 승격 기준을 통과해야 한다

A4/B4/C5의 승격은 문서 정확도뿐 아니라 설명, 수학, 일반 언어 유지 조건을 함께 요구했다. 특히 유효 설명 87개 기준은 설명이 정답을 포함하므로 정답 73개만으로 충족할 수 없다. 이 구조를 숨기거나 결과를 본 뒤 유리하게 완화하지 않았다.

여섯 저장본 모두 전체 기준을 충족하지 못해 두 번째 시드의 확인과 봉인 최종 평가를 실행하지 않았다. 개별 항목을 통과한 경우까지 '모든 게이트 실패'라고 부르지 않고 전체 승격 요건 미충족으로 기록한다. B4-075는 보조 진단 대상으로 살펴본 후보이지 승격된 최종 모델이 아니다.

예산이 남아 있다는 사실은 좋은 결과를 얻을 때까지 무한히 선택해도 된다는 뜻이 아니다. 사용자가 추가 실험을 한 차례만 더 허용한 뒤에는 새 R6 프로토콜을 분리하고 그 결과로 연구를 동결했다.

근거: 훈련 전 동결한 다섯 기준과 전체 후보 개발 검수 · 공개 데이터 키: candidate-gates

31. 웹 GPT의 반론으로 AI 채점의 일관성을 바로잡다

학습 목표의 일부 설명은 조건을 나열하고 해당자가 없다고 결론만 제시했다. 당시 합의한 기준은 핵심 조건과 필터 결과가 정확하면 짧은 설명도 허용했지만, 초기 AI 판정 일부는 0명일 때만 모든 개인의 배제 이유를 요구했다. 웹 GPT Pro가 학습 목표와 평가 기준의 불일치를 지적했다.

후보 보정 일부를 본 뒤, 후보 개발평가를 시작하기 전에 해당 기준을 정리하고 모든 관련 모델의 0명 교집합 응답에 같은 정정을 적용했다. 이 시점 때문에 전체 절차를 수정 없는 사전등록이라고 부르지 않는다. 정정 전·후 기록과 기준 변경의 이유를 보존했다.

이 사례는 두 AI가 이야기를 나누면 객관성이 자동 확보된다는 뜻이 아니다. 오히려 동일한 기준을 실제 답변에 적용할 때도 판정이 흔들릴 수 있음을 보여 준다. 마지막 R6에서는 더 상세한 풀이를 쓰고 설명·인용 기준을 명확히 했지만 그 역시 단일 AI 판정의 한계를 갖는다.

근거: 원래 루브릭 v3, 원판정, 48개 관련 응답 재검토와 버전별 정정 5건 · 공개 데이터 키: review_consistency

V. 마지막 한 차례: R6 회복 실험

32. 마지막 실험 전, 어댑터 강도만 바꿔 손실을 확인하다

B4-075에서 기본 모델만 맞힌 문서 25개 중 청구액 6개와 가중점수 6개가 12개,48%였다. 후보만 맞힌 10개가 일부 손실을 상쇄하여 전체 차이는-15개였다. 정답률 하나보다 어느 유형에서 능력이 줄었는지를 먼저 확인했다.

같은 기반 모델과 같은 56개 진단 문항을 두고 어댑터 적용 강도를 0·0.25·0.5·1로 바꿔 224응답을 생성했다. AI 의미 재검수 후 문서 24개 정답은 21·16·17·10개, 수학 16개는 12·13·14·13개였다. 강도 0은 어댑터를 실제 비활성화한 대조다. 자동 문자열 채점의 초기 값과 의미 재검수 값은 다르므로 후자를 사용했다.

문서에서 완전 적용은 기본 대비 단독승 0·단독패 11개였고 평균 출력 토큰도 173에서 50.375로 줄었다. 그러나 수학은 단조롭게 나빠지지 않았다. 이 작은 노출 진단은 기존 어댑터가 문서 성능 저하에 관여한다는 증거이지, 학습률·데이터·목표 길이 중 어느 하나가 원인인지 분리한 실험은 아니다.

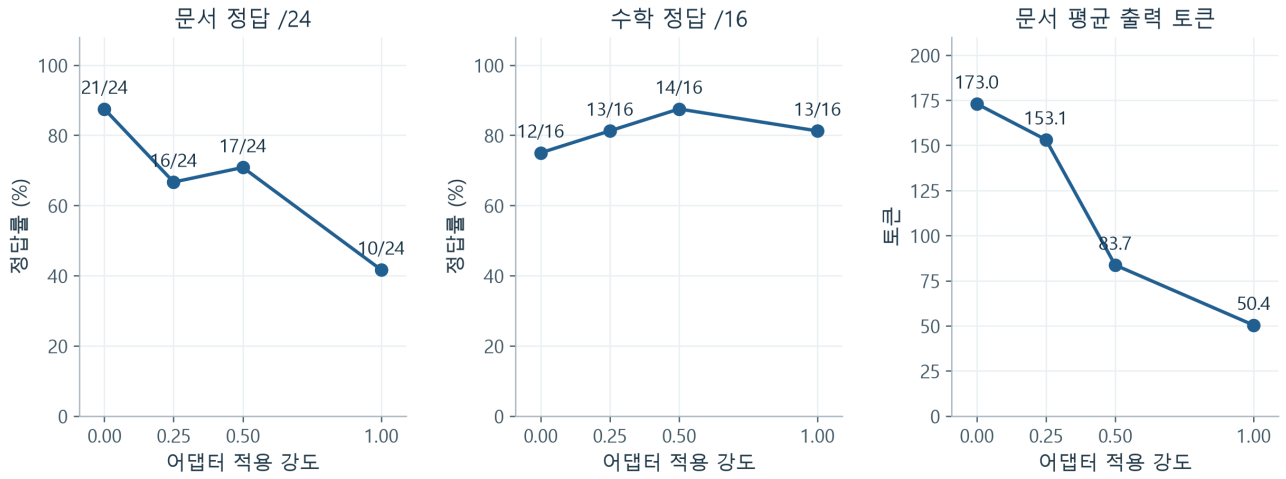


그림 9. 적용 강도만 바꾼 같은 진단 표본. 의미 재검수 결과이며 문서 24·수학 16·KoBEST 16의 작은 노출 표본이다.

근거: 2026-10-27 추가 회복 실험의 고정 설정과 실측 자료 · 공개 데이터 키: recovery-adapter-dose

33. 계산 단계를 드러낸 960행을 새 기반 모델에 학습하다

R6는 기존 문서 600개의 정답을 유지하면서 풀이를 상세화했다. 이용 시간은 시각을 분으로 바꾸고, 청구액은 상품액·할인·배송비를 나누어 계산하며, 가중점수는 곱과 합을 모두 표시했다. 쿠폰의 몫·나머지, 사람별 조건 충족 여부도 드러내도록 목표를 구성했다. 최종 답을 맞히는 것과 필요한 설명을 제공하는 것을 함께 겨냥했다.

여기에 GSM8K 공식 train의 240개 원본 풀이와 기존 SQuAD train 근거 예제 120개를 합쳐 총 960행을 만들었다. test 문제나 미사용 최종 정답을 학습 자료로 옮기지 않았다. 감독 토큰은 98092개, 최대 입력 길이는 1191토큰으로 상한 1536 안에 있었고 잘림은 없었다.

데이터 구성, 더 상세한 풀이, 낮춘 학습률을 함께 바꾼 복합 보완이다. 결과가 좋아진 부분을 한 요소만의 인과 효과로 배분할 수 없다. 또한 같은 문서 유형을 훈련·개발에서 다루므로 유형 일반화보다 해당 작업군의 회복을 탐색한 실험이다.

출처	행	감독 토큰
GSM8K 공식 train 원본 풀이	240	22073
기존 합성 학습 문서의 상세 풀이	600	69591
기존 SQuAD train 근거 문장 재생	120	6428

근거: 2026-10-27 추가 회복 실험의 고정 설정과 실측 자료 · 공개 데이터 키: recovery-data

34. 재측정 기준선과 선정 하한을 후보 결과 전에 고정하다

추가 학습 전에 S0를 같은 개발 176문항에 다시 실행했다. 문서 96출력은 이전 S0와 모두 같아 동일 문항·응답의 기존 내용·설명 판정을 재사용했다. 공개 평가의 자동 비일치 11건은 이번 차수에 다시 검수했고 통화 표기 2건을 의미 정답으로 인정했다. 기준선은 문서 68·수학 35·유효 설명 42·KoBEST공식 36·오류수정 37로 같았다.

선정은 문서에서 S0보다 최소 5개 더 맞히고 나머지 수학·설명·언어 지표는 S0 이상이어야 했다. 재측정이 우연히 낮아져 조건이 쉬워지지 않도록 과거 기준선의 하한도 함께 적용했다. 결과적으로 문서 73/96, 수학 35/40, 설명 42/96, 공식 Ko36/40, 수정 Ko37/40이 고정 기준이었다.

동률·후보 우선순위와 조건부 최종 평가 방법도 동결했다. 로컬 해시 봉인은 파일 변경을 확인하는 수단이지 외부 사전등록·외부 시각 인증이 아니다. 후보를 본 뒤 기준을 낮추지 않는 운영 통제를 사용했다는 범위로 설명한다.

근거: 2026-10-27 추가 회복 실험의 고정 설정과 실측 자료 · 공개 데이터 키: recovery-selection-design

35. 120단계 한 번, 세 체크포인트,6분 48초의 학습

고정 EXAONE 리비전 553ea250b9a5317231459279d5847d6cf955b9aa를 NF4 이중 양자화와 BF16 계산으로 불러왔다. q/k/v/out 투영의 LoRA는 rank16·alpha32·dropout0.05였고 학습 가능 매개변수 13631488개, 양자화 선형 모듈 224개를 확인했다. 학습률 1e-5, 실제 배치 1·누적 8, 시드 20261027을 사용했다.

960행을 1epoch,120업데이트로 한 번 학습하고 40·80·120단계에 저장했다. 기록된 학습 경과는 407.6018초, 약 6분 48초다. 최고 torch allocated9.450GiB는 프레임워크가 할당한 메모리이며 장치 전체 VRAM 사용량이나 임대 시간과 다르다.

앞 10배치 평균 손실 2.231에서 뒤 10배치 0.894로 낮아졌지만 서로 다른 배치를 비교한 학습 목적함수다. 이 하강을 곧바로 수학·문서 능력 향상으로 해석하지 않았다. 각 저장본을 다시 불러와 실제 생성·채점을 수행하고 백업 해시를 확인했다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-training-execution

36. 부분 회복은 컸지만 전체 승격 요건은 충족하지 못했다

40·80·120단계 문서 정답은 46·57·55개, 수학은 34·31·34개였다. 학습이 진행될수록 모든 점수가 단조롭게 상승하지 않았다.80·120단계의 유효 설명 45·44개는 S0의 42개보다 많았지만 문서 정답과 수학 기준을 함께 만족하지 못했다.40단계는 설명 기준도 미달했다.

기존 ARGOS6/40에서 R6-040·120의 34/40으로 오른 수학 최종답 점수는 큰 부분 회복이다. 다만 S0 35/40와 1개 차이라는 사실만으로 통계적 동등성이나 모든 중간 추론의 복구를 선언할 수 없다. 공개 40문항을 이미 여러 번 보며 개발한 결과이고 새 최종 수학을 실행하지 않았다.

선정 후보는 null, 전체 승격 요건 통과는 0개로 기록됐다. 결과가 마음에 드는 부분만 고르고 기존 강점의 손실을 생략하지 않았다. 연구자에게 만족스러운 개선이 있었다는 사실과 사전 승격 요건을 통과했는지는 별개다.

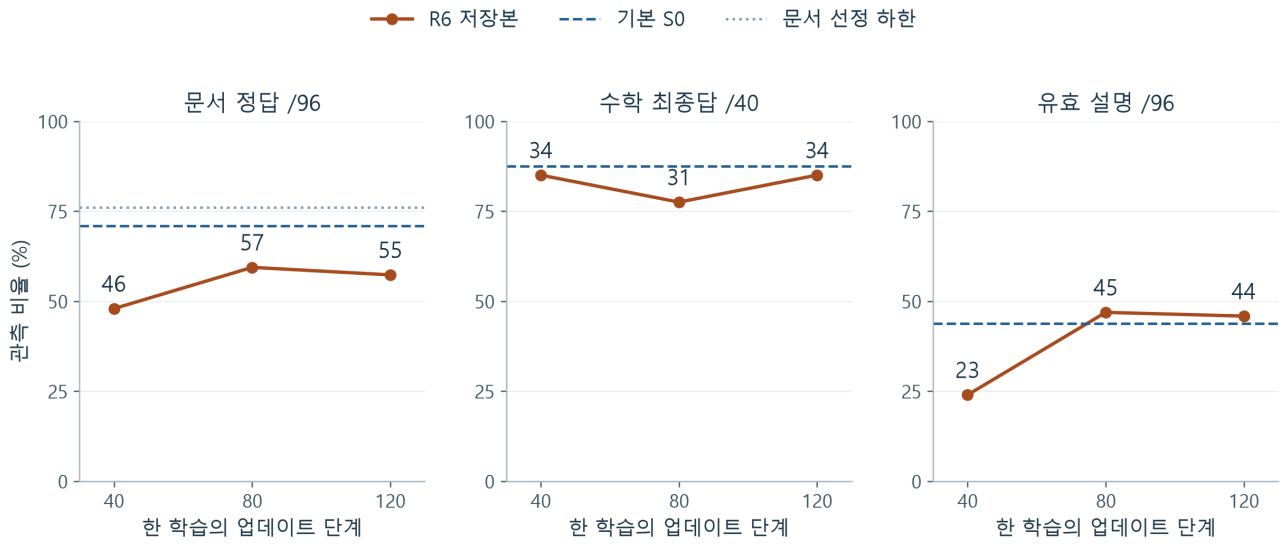


그림 10. 하나의 R6 학습에서 저장한 세 지점. 점선은 같은 개발 평가의 S0 기준선이며 독립 최종 성적이 아니다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-gate-results

37. 청구액은 회복했지만 가중점수 손실이 남았다

각 유형은 8문항이다. 청구액은 B4-075의 1/8에서 R6-080·120의 7/8로 늘어 S0의 7/8과 같아졌다. 상세한 계산 목표를 도입한 뒤 관측된 유형별 회복이다. 그러나 가중점수는 S0 6/8에 비해 R6가 1·1·0/8로 낮았고, 수학 전반의 해결로 확대할 수 없었다.

R6-120은 업체 선택 8/8과 초과 요금 8/8에서 좋은 결과를 보였지만 재고 3/8·정보 부족 5/8·최신 담당자 3/8은 S0의 7·8·4개보다 낮았다. 한 유형을 고치며 다른 유형을 유지하지 못한 교환관계가 남았다. 히트맵은 모든 유형과 동일 분모를 보여 주어 좋은 사례만 선택하는 해석을 줄인다.

유형별 8개라는 작은 표본에서의 최대·최소를 모집단 순위로 확정하지 않는다. 이 분석은 후속 오류 이해를 위한 개발 자료이며 이미 종료한 모델 선택을 다시 여는 근거로 사용하지 않았다.

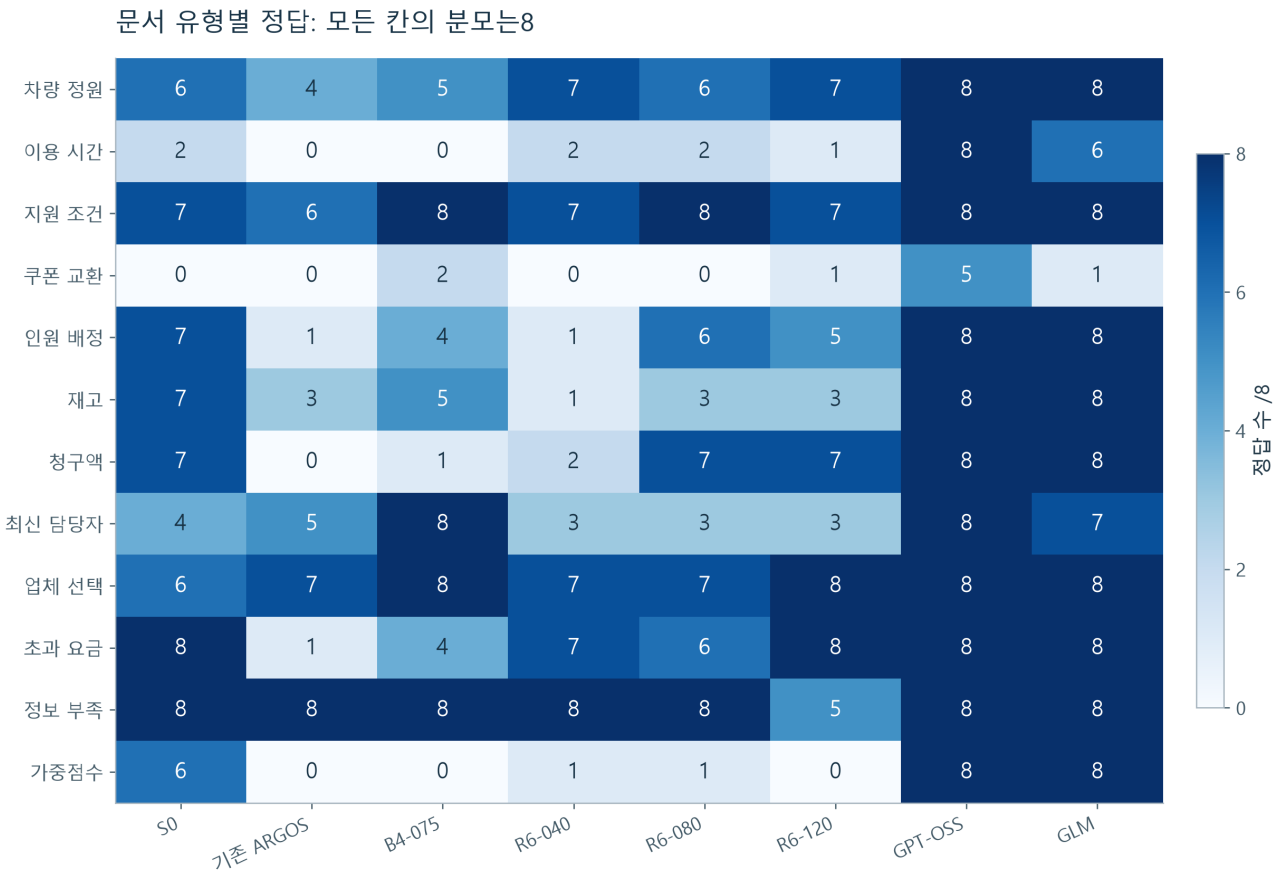


그림 11. 문서 12유형×8문항의 정답 수. 색 범위는 모든 칸에서 0–8로 같고 표 안 숫자가 실제 정답 수다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-families

38. 같은 문항의 이득과 손실을 나누면 순차이가 설명된다

R6-120의 문서 정답 55개와 S0의 68개 차이-13개는 후보만 맞힌 8개와 기본만 맞힌 21개의 차이다. 수학 34개와 35개 차이-1개는 후보만 맞힌 4개와 기본만 맞힌 5개의 차이다. 작은 순차이 뒤에 서로 다른 문항의 성공과 실패가 있음을 보여 준다.

R6-080은 문서에서 단독승 7·단독패 18, 수학에서 3·7이었다.40단계도 동일 방식으로 연결했다. 각 차이를 공개 문항 ID로 재계산하면 전체 정답 수 차이와 정확히 일치한다. 단순 총점으로는 드러나지 않는 대체와 상쇄를 확인하는 분석이다.

이 표에 새 유의성 판정을 붙여 반복 사용한 개발셋을 최종 확인처럼 만들지 않았다. 선정에 쓰인 같은 자료에서 무엇이 바뀌었는지를 설명하는 기술통계로 제한한다. 독립 최종의 신뢰구간·우월성·비열등성은 미측정이다.

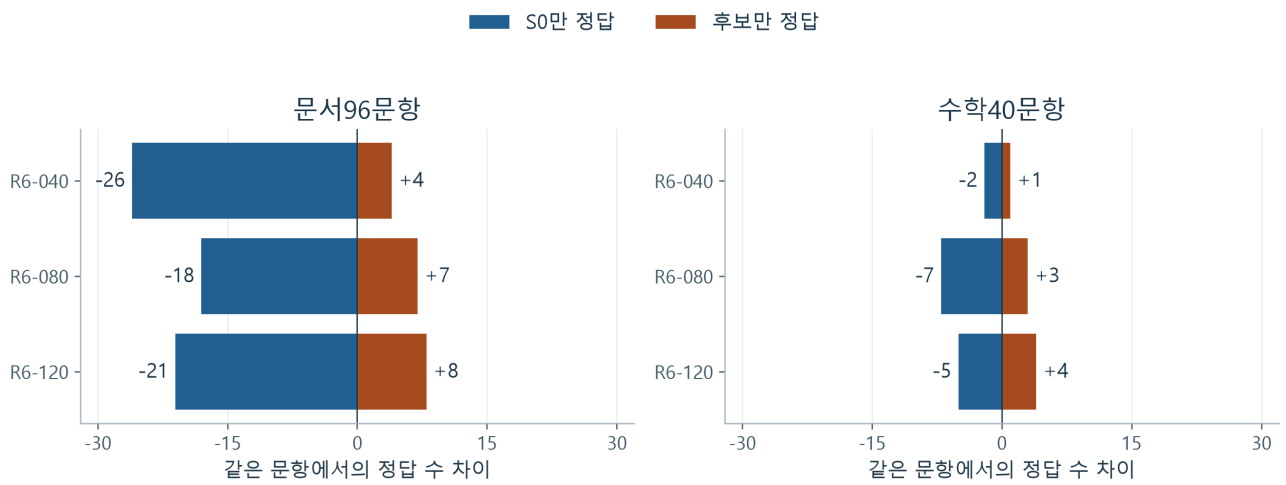


그림 12. 같은 문항에서의 단독승과 단독패. 오른쪽은 후보의 이득,왼쪽은 기본 모델 대비 손실이다.

후보	과제	문항	후보만 정답	S0만 정답	순차이
R6-040	문서	96	4	26	-22
R6-040	수학	40	1	2	-1
R6-040	KoBEST 공식	40	0	0	0
R6-080	문서	96	7	18	-11
R6-080	수학	40	3	7	-4
R6-080	KoBEST 공식	40	0	0	0
R6-120	문서	96	8	21	-13
R6-120	수학	40	4	5	-1
R6-120	KoBEST 공식	40	0	0	0

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-paired-results

39. 정답을 맞히고도 계산·인용이 틀린 답을 구분하다

마지막 문서 응답 384개의 설명 상태를 채웠다. 기본 96개는 동일한 저장 응답의 판정을 재사용했고 새 후보 288개는 이번에 읽었다. 공개 자동 비일치 44개까지 포함한 기록된 검수는 428건이다. 이것은 428개의 독립 새 문항이나 사람 428회 검수를 뜻하지 않는다.

요청한 업체명은 맞지만 추가 가격을 잘못 설명한 답은 최종 결론 정답, 설명 실패로 분리했다. 문서 번호를 썼다는 사실만으로 인용이 충분하다고 판정하지 않고, 실제 주장과 계산이 해당 문서의 근거에 맞는지 보았다. 최종 정답과 중간 설명의 충돌도 별도로 확인했다.

R6 검수는 Codex 단일 AI의 비블라인드 판정이었다. 사람 두 명의 재채점이나 R6 전체 주장 단위 감사, 새로운 자연스러움·쌍대평가는 수행하지 않았다. 기존의 두 AI 검수 기록이 있다는 이유로 이 단계까지 이중 검수했다고 표시하지 않는다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-error-evidence

VI. 주장·선호·통계로 다시 읽는 성과

40. 798개 주장 감사: 짧은 답과 낮은 오류율은 같은 말이 아니다

A4/B4/C5 단계에서는 유형당 2개씩 고정한 24문서를 5개 모델에 적용한 120응답을 주장 단위로 분석했다. 총 798개 주장이다. S0는 251개 중 32개 모순(12.75%), 기존 ARGOS는 69개 중 19개(27.54%), B4-075는 77개 중 27개(35.06%)였다. GPT-OSS는 216개 중 1개(0.46%), GLM은 185개 중 4개(2.16%)였다.

문서 정답과 수학 최종답이 회복된 B4가 이 보조 표본의 주장 모순율까지 낮춘 것은 아니었다. 답변당 주장 수가 크게 달라 비율과 총 주장 수를 함께 표시했다. GLM은 24개 중 1개가 미완료·무주장이므로 이를 완전한 무오류 답으로 해석하지 않는다.

분해와 주석은 단일 AI의 기록이다.798개 주장은 798명의 독립 관측이나 798문항이 아니며, 같은 답변 안의 주장은 상관될 수 있다. 전체 모집단의 사실 오류율로 확대하지 않고, 이미 실패한 승격을 보완 점수로 구제하는 데 사용하지 않았다.

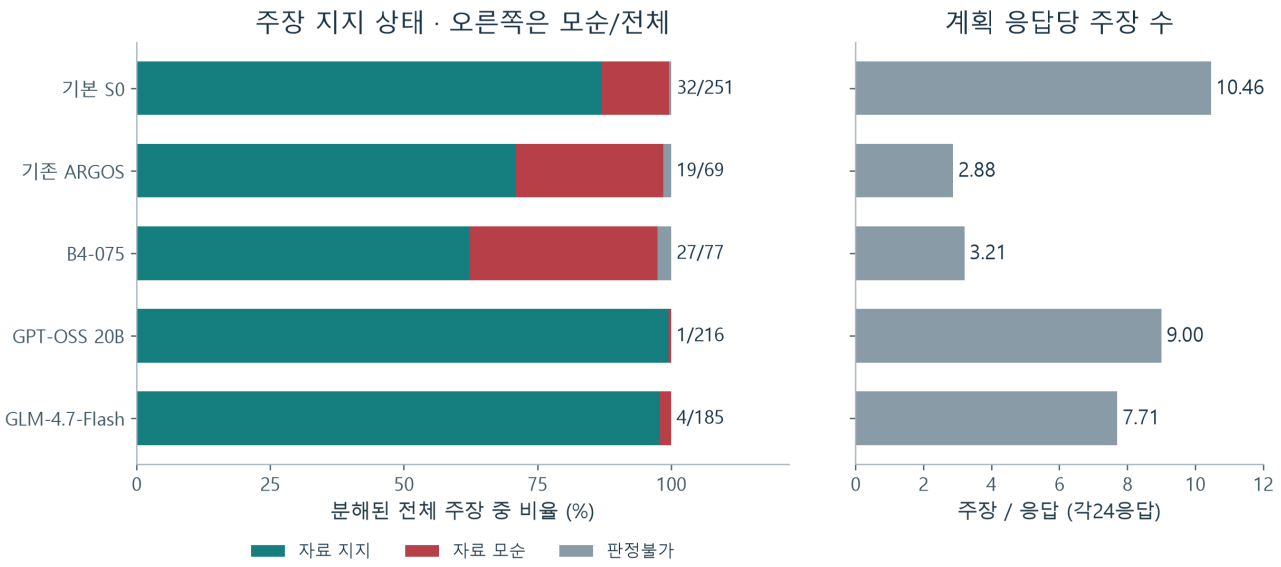


그림 13. 같은 24개 문서에 대한 모델별 주장 분해. 주장 수·모순율의 분모가 모델마다 다르며 인간 검수는 0명이다.

모델	완료응답	지지	모순	판정불가	전체주장	모순비율
기본 S0	24/24	218	32	1	251	12.75%
기존 ARGOS	24/24	49	19	1	69	27.54%
B4-075	24/24	48	27	2	77	35.06%
GPT-OSS 20B	24/24	215	1	0	216	0.46%
GLM-4.7-Flash	23/24	181	4	0	185	2.16%

근거: 같은24문항·5모델의120응답, 명시적으로 기록한798개 원자 주장 · 공개 데이터 키: baseline-claims

41. 72쌍·두 AI의 판정: 종합 선호와 자연스러움의 일치가 달랐다

같은 24문항에서 B4-075를 S0·GPT-OSS·GLM과 비교한 72쌍을 익명 A/B로 구성했다. Codex와 프로젝트 ChatGPT Pro의 최초 판정 144개를 보존했다.72쌍은 24개의 고유 질문을 세 비교에 반복한 것이며 144개의 독립 문제도 아니다. 두 평가자는 관련된 AI이고 설계·프로젝트 이력을 공유한다.

종합 선호는 57/72 일치(79.17%), Cohen κ=.6355였다. 자연스러움은 19/72 일치(26.39%), κ=.1365였고 Pro는 동률 51개, Codex는 0개를 사용했다. 자연스러움의 낮은 일치는 점수 정의와 동률 적용의 영향을 보여 준다. 사람 간 신뢰도나 객관적 문체 품질의 확정값으로 쓰지 않는다.

종합 선호에서 B4 대 S0는 Codex15승 9패, Pro13승 9패 2무였다. 그러나 교사와의 비교는 두 AI 모두 후보의 패배가 더 많았다. 짧은 답의 유용성에 대한 국소 선호와 정확도·사실성·교사 초월은 서로 다른 결론이다.

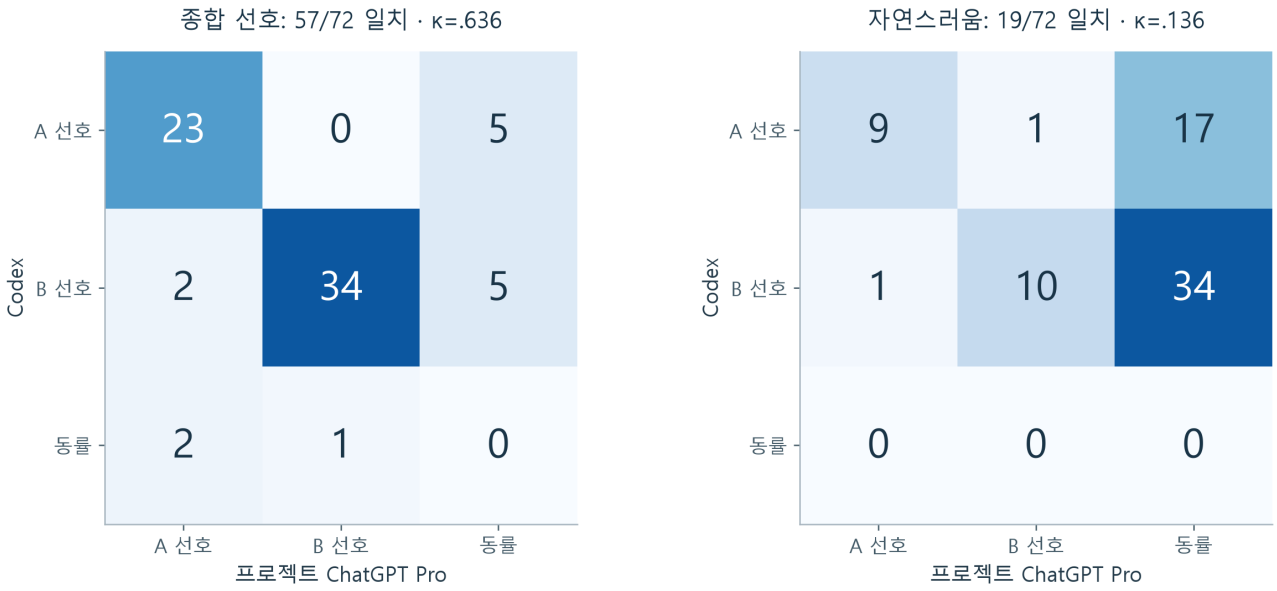


그림 14. 같은 72쌍에서 두 AI의 첫 판정을 연결한 교차표. 인간 평가자 일치도는 측정하지 않았다.

기준	쌍	일치	일치율	κ
종합 선호	72	57	79.17%	0.6355
한국어 자연스러움	72	19	26.39%	0.1365

근거: 같은 익명72쌍에 대한 두 AI의144개 최초 판정 · 공개 데이터 키: pair-agreement

42. 실행 시간과 자원 효율의 측정 범위

원래 새 확인 720응답의 로컬 생성 호출 합계는 S0 약 955.94초, ARGOS262.98초였다. 출력 토큰은 35671개와 5980개로 크게 달랐고, 생성초당 토큰은 37.32와 22.74였다. ARGOS의 호출 시간이 짧다는 사실을 더 높은 토큰 처리 속도나 동일 답변 품질의 효율 우위로 바꾸면 안 된다.

후속 A5000 문서 96개에서는 B4-075 중앙 지연 2.18초, 기존 ARGOS1.22초, S0 5.33초가 관측됐다. 답 길이·프롬프트·추론 방식이 달라 구조 자체의 속도 차이로 분리하지 않았다. TTFT는 별도 계측하지 않았고, 로딩·입력 토큰화가 빠진 생성 지연을 전체 사용자 체감 시간이라고 부르지 않는다.

과거 특정 단계의 GPU 표본 에너지 1342.56Wh와 약 18.23시간·단순 연산요금 4.92달러·계정차감 5.95달러 기록도 범위가 제한돼 있다. 이것을 프로젝트 전체 전력량·40달러의 완전한 청구 내역·사용자의 PC96시간 전력 사용량으로 환산하지 않는다.

근거: 전체 문서 개발 응답의 저장된 latency_seconds·ttft_seconds와 최종 출력 길이 · 공개 데이터 키: runtime-latency

VII. 동결·비용·시간과 연구의 완결

43. 봉인한 최종 280문항은 실행하지 않고 연구를 동결했다

R6 최종용 합성 문서는 200개로, 기존 12연산군의 새 문서 160개와 새 조합 40개다. 여기에 이전에 추론하지 않은 공개 80문항을 더했다.280개 모두 새 비공개 문제라는 뜻이 아니다. 학습 전 정답·중복 검증과 로컬 해시 봉인을 완료했고 공개물에는 문제·정답·복원용 생성 정보를 넣지 않았다.

전체 승격 조건을 만족한 후보가 없어 최종 추론은 0건이었다. 성능은 미측정이며 0%가 아니다. 두 번째 시드, 추가 후보 선택, 최종 우월성·비열등성 검정도 실행하지 않았다. 봉인 파일이 있다는 것과 최종 평가 결과가 있다는 것을 구분한다.

가중치·응답·판정의 백업 해시를 검증하고 2026년 10월 27일 15:01:20 KST에 GPU 중지 상태를 확인했다. 이후 사용자는 수학 회복 수준에 만족하고 최종 마감을 지시했다. 이번 보고서 작성은 역사·통계·시각화·공개 정리이며 새로운 학습이나 추론을 수행하지 않았다.



그림 15. 실행된 확인 평가와 개발 승격 실패 후 미실행으로 남긴 최종 평가를 분리했다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-closure

44. 통계가 말해 주는 것과 말해 주지 않는 것

정답률은 확인된 정답 수를 전체 계획 분모로 나누었다. 미완료·미확정은 성공 분자에서 빼고 분모를 유지했다. 각기 다른 과제의 비율을 더해 종합 지능점수를 만들지 않았다. 동일 문항 비교는 단독승·단독패를 연결하고, 새 S5 확인에는 문항 부트스트랩과 유형 단위 민감도 구간을 사용했다.

예를 들어 새 수학의 ARGOS-S0 차이는-38.75%p였고 95% 문항 구간[-52.5,-25.0], 유형 구간[-58.75,-18.75]였다. 정확 출력의+60%p는 전체 문자열 규약에 대한 이득이며 일반 추론 향상과 다르다. 여러 과제의 탐색적 비교로 다중비교 보정은 없었고, 구간은 고정된 체크포인트·AI 판정에 조건부였다.

개발 결과를 여러 번 보고 만든 R6에는 같은 방식의 유의성 수치로 새 독립 우위를 주장하지 않았다. 작은 표본의 1문항 차이로 동등성이나 비열등성을 선언하지 않는다. 주장들은 응답 안에, 쌍대 비교들은 같은 질문 안에 묶여 있어 독립 표본 수를 주장 수나 판정 수로 부풀릴 수 없다.

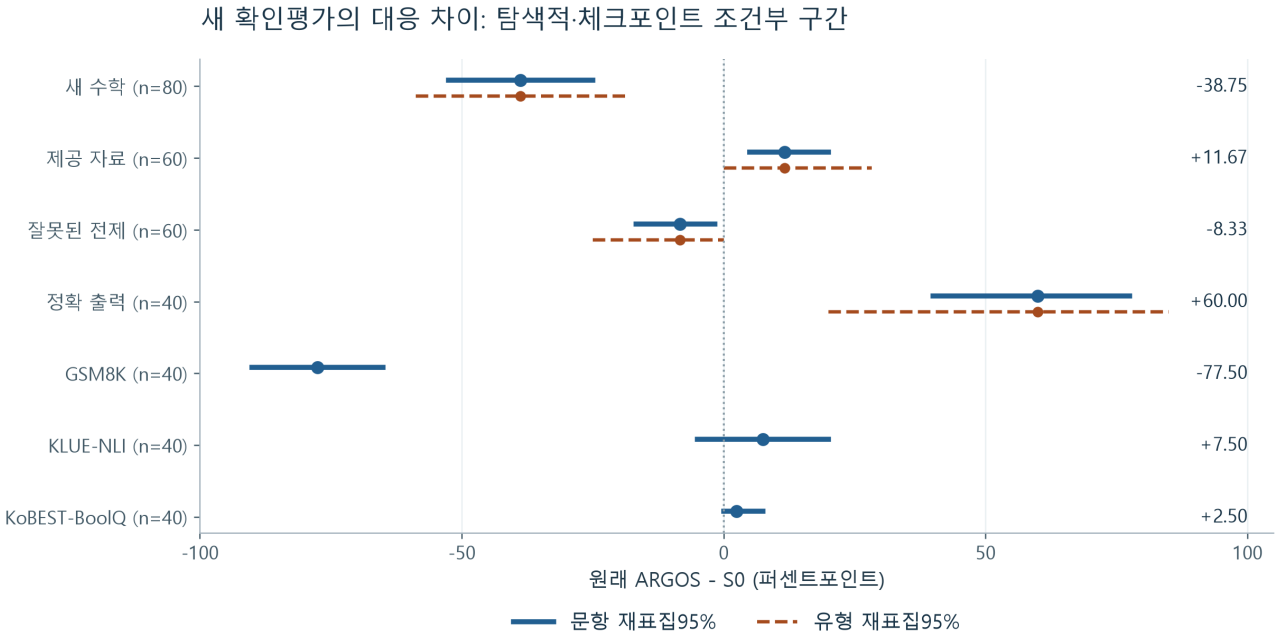


그림 16. 원래 S5의 새 확인평가에서 ARGOS-S0의 차이와 95% 대응 재표집 구간. 실선은 문항, 점선은 사용 가능한 합성 문제 유형 단위 민감도다. 탐색적 비교이다.

근거: 원래 신규 확인 comparisons.json: 대응 문항·문제 유형 부트스트랩 · 공개 데이터 키: synthesis-confirmation-statistics

45. 전체 40달러와 마지막 차수의 계정 차감은 범위가 다르다

사용자는 이 프로젝트에 든 총비용을 40달러라고 보고했다. 본문은 이를 전체 프로젝트 지출의 사용자 보고값으로 기록한다. 전체 영수증을 전수 대조한 확정 청구서나 순수 학습 GPU 요금으로 표시하지 않는다. 임대 초기 수집·실패·준비·후속 평가 등 전체를 새로 항목별 복원할 근거는 부족하다.

별도로 마지막 추가 예산 관측 시작 이후 계정 차감은 2.223714달러, 그 안의 R6차수는 0.457273달러였다. 앞선 A4/B4/C5 종료 시점의 1.620186달러와 최신 수치는 서로 다른 시점·범위이므로 무리하게 차액을 특정 작업비로 이름 붙이지 않는다. R6 차감에는 준비·추론·백업과 기존 중지 저장소 비용이 섞일 수 있다.

40+2.22+0.46으로 총비용을 다시 더하지 않는다. 남은 예산이나 실제 계정 잔액도 공개하지 않았다. 저장소 보관료는 GPU 중지 이후에도 발생할 수 있어 관측 종료 시점과 이후 요금을 분리한다. 이번 작성 단계에서는 추가 GPU 학습을 실행하지 않았다.



그림 17. 전체 비용·PC 가동·기록 활동 구간은 서로 다른 종류의 값이다. 합산하거나 같은 시간으로 환산하지 않는다.

범위	USD	근거	해석
프로젝트 전체 지출	40.0	사용자 보고	영수증 전수 대조 없음; 총액40달러로 기록
후속 $10 관측 시작 이후	2.223714	계정 차감 관측	전체40달러와 범위가 다른 부분 기간. 총액에 더하지 않음
마지막 R6 차수	0.457273	계정 차감 관측	바로 위 관측 기간에 포함; 준비·추론·백업·보관료가 섞일 수 있음

근거: 사용자의 총액 보고 + 공개 recovery_cost_and_stop.json · 공개 데이터 키: synthesis-cost

46. 얼마나 시간을 쏟았는가: 기록으로 산출 가능한 범위

사용자는 집중 작업 중 PC를 4일간 계속 켜 두었다고 보고했다.4×24=96시간은 장비 가동·감시 환경 유지 시간이며 직접 화면을 보며 일한 96시간이나 GPU 학습 96시간을 뜻하지 않는다. 기록상 연구 설계와 종료는 8월 9일~10월 27일, 날짜 차이 79일에 걸쳐 있다. 이 기간도 노동시간과 다르다.

프로젝트 경로에 해당하는 Codex 로그 5개에서 사용자 역할 기록 387건을 추출했다. 자동 감시 heartbeat143건과 환경·페이지·플러그인 삽입 67건을 제외해 177건을 남겼다. '필터링 후 사용자 역할 기록'이라는 표현을 사용하며,177개가 모두 독립적인 수작업이라는 보장은 하지 않는다. 기록이 존재하는 한국시간 날짜는 8월 15일과 10월 22~27일의 7일이다.

여러 로그의 기록을 합쳐 시각순으로 정렬하고, 동일 시각·본문 해시 중복을 제거한 뒤 인접 입력 사이 간격이 15·30·60분 이하이면 같은 구간으로 연결했다. 각 구간의 마지막-첫 입력 시각을 합산했으며 단독 입력은 0시간이다. 겹치는 로그를 각각 더하지 않았다. 전체 연결 구간 합계는 6.97·13.92·21.46시간,10월 23~27일만 보면 6.43·11.67·16.82시간이다.

대표적으로 30분 규칙의 13.92시간을 제시하되 이는 로그 연결 지표다. 대기·자리 비움이 들어갈 수 있고 메시지 없이 읽기·검토·웹 ChatGPT에서 진행한 초기·중기 작업은 빠진다.6.97~21.46은 실제 노동시간의 추정 범위나 신뢰구간이 아니다. 따라서 전체 직접 작업시간은 기록만으로 확정하지 않았다. 공개 묶음은 원문·정확한 개인 시각 없이 익명 구간 지속시간을 제공해 합계 산술만 재확인할 수 있게 했다.

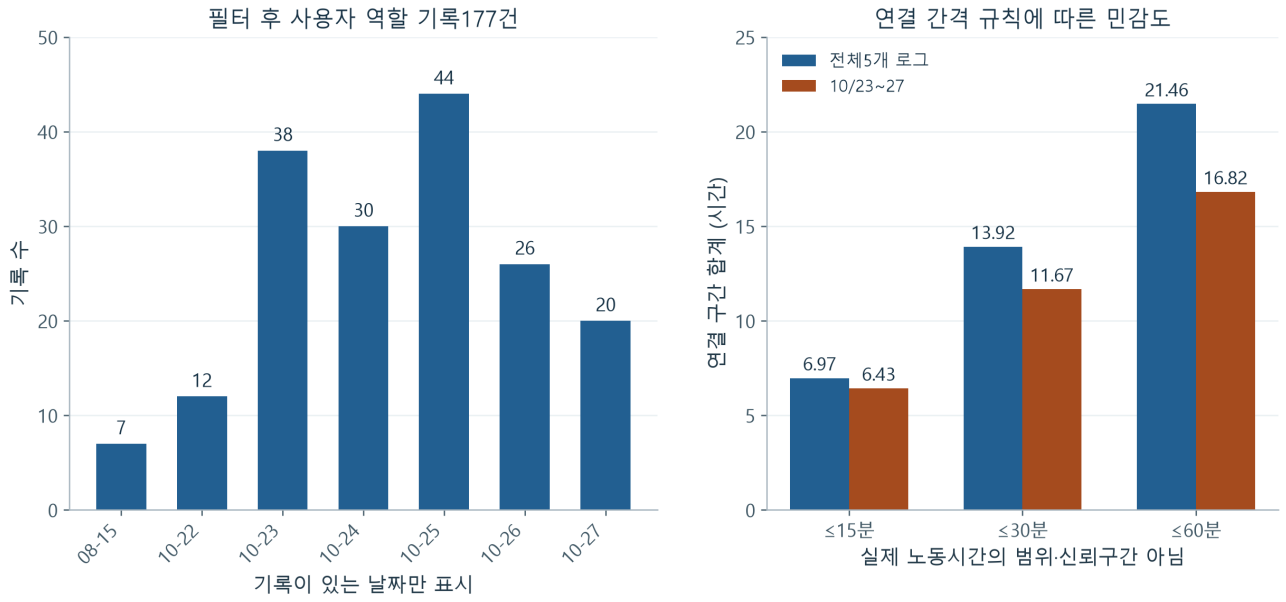


그림 18. 필터 후 사용자 역할 기록과 연결 규칙의 민감도. 점선·오차막대의 노동시간 추정이 아니라 세 가지 다른 계산 규칙의 결과다.

연결 기준 분	구간 수	전체 구간 시간	10/23~27 시간
15	57	6.973	6.431
30	37	13.922	11.673
60	27	21.464	16.816

근거: 프로젝트에 해당하는 Codex 로그5개: 자동 호출·환경 삽입을 제외한177개 사용자 입력 · 공개 데이터 키: synthesis-activity

47. 공개 보고서에서 재계산할 수 있는 범위

공개 묶음에는 PDF·Markdown·오프라인 HTML, 표와 그림의 근거 자료, 합성 개발 응답·판정, 공개 벤치마크 식별자·정답·출력·채점, 주장 분해와 두 AI의 최초 쌍대판정을 포함했다. 실제 학습·데이터·코드·어댑터의 고정 리비전과 해시를 보존했다. 모델 가중치, 개인 대화 원문·URL, 인증정보, 실제 계정 잔액·자원 식별자와 미사용 최종 문항은 공개하지 않았다.

code/recompute_public_report.py는 이전 1760개 비교 응답과 주장·쌍대 집계를 검증한다. recovery-code/recompute_round.py는 마지막 704개 개발·224개 진단, 학습 영수증과 모든 승격 조건을 재계산한다. 연구 후속 두 차수의 표준 응답은 3128+928=4056개이며 별도 런타임 프로브 8개는 따로 센다. 원래 교사 수집·확인 720응답과 중복된 범위로 무리하게 하나의 고유 문항 총계를 만들지 않았다.

새 report-code는 동일한 공개 canonical 데이터에서 그림·PDF·Markdown을 만들고 보고서의 표·그림·수치 연결을 점검한다. 재계산은 저장된 AI 판정의 산술·무결성 검증이며 의미 타당성을 새로 심사하는 독립 검

수가 아니다. 비공개 입력과 가중치가 없으므로 전체 학습을 공개 묶음만으로 재실행할 수 있다고 주장하지 않는다.

근거: 공개용 허용 목록과 공개 재계산 스크립트 · 공개 데이터 키: public-reproduction

48. 최종 질문에 대한 답: 향상, 회복, 교사 초월

첫째, 실제 모델을 만들었는가? 그렇다. 교사 응답 수집, 데이터 검증, 어댑터 학습·저장·재로딩, 실제 추론·채점·백업까지 수행했다. 둘째, 좋아진 지표가 있는가? 그렇다. 초기 Pilot의 소규모 통과 증가, 원래 S5의 자료 충실도·정확 출력, 일부 특화 표본의 교사 대비 관측 우세, 후속 개발에서 수학 최종답 점수 회복이 있었다.

셋째, 기본 모델보다 전반적으로 좋은가? 입증하지 못했다. 원래 ARGOS의 의미·수학 저하가 컸고, R6도 문서·수학·설명·언어의 전체 승격 요건을 만족하지 못했다. 넷째, 교사를 넘었는가? 일부 표본의 점수는 앞섰지만, 사전에 고정된 새 독립 평가와 반복 검증을 갖춘 부분 초월 또는 두 교사 전반의 우월성은 입증하지 못했다.

마지막 R6가 수학 34/40을 얻었다는 성과는 분명히 기록할 만하다. 다만 R6-120은 문서 55/96으로 S0 68/96, GPT93/96, GLM86/96보다 낮다. 한 지표의 회복을 모든 능력의 회복으로 바꾸지 않고, R6의 최종 독립 성능은 미측정이라고 남긴다.

근거: 계획서의 연구 질문과 완료된 단계별 결과 · 공개 데이터 키: synthesis-questions

49. 미수행 평가와 남아 있는 불확실성

독립 사람 2명의 문항·정답 근거 검수, 사람 설명·자연스러움·블라인드 선호 판정 및 사람 간 일치도는 완료되지 않았다. 원래 새 확인의 단일 AI 검수, 일부 후속 72쌍의 두 AI 판정, 마지막 R6의 비블라인드 단일 AI 검수는 서로 다르다. 웹 GPT와 보고서를 협의한 활동도 사람 검수나 R6 재채점으로 환산하지 않는다.

모든 계획 벤치마크의 전체 실행, 광범위한 개방형 질의·코딩·한국어 전 영역의 성능, R6 전체 주장 감사, 두 번째 학습 시드와 독립 최종 검정은 수행하지 않았다. KMMLU100, GSM8K·KLUE·KoBEST 각 40 등 실행한 부분집합의 범위만 보고한다. 실제 사용 모델은 초기 대형 교사와 다르며 평가자의 공유 맥락·양자화·생성 조건 차이도 남아 있다.

합성 문서의 규칙성, 같은 개발셋의 반복 사용, 교사 불일치 중심 자료의 선택 편향, 정답표와 AI 설명 판정의 오류 가능성은 외적 타당성을 제한한다. 원시 자료 공개와 해시 검증은 이 한계를 줄이는 투명성 장치이지 없애는 장치가 아니다. 비용과 시간도 사용자 보고·계정 관측·로그 지표로 분리한다.

근거: 단계별 프로토콜·봉인·실행 영수증 · 공개 데이터 키: synthesis-evaluation-generations

50. 연구를 마감하며: 성능 성공과 연구 완결은 다르다

본 연구는 학교 탐구의 아이디어를 실제 임대 GPU·오류 복구·데이터 장부·학습·평가·통계·공개 산출물로 연결했다. 제한된 예산에서 실행 가능한 시스템을 만든 공학적 성과와, 검증·형식 중심 학습이 능력 보존을 자동 보장하지 않았다는 관측을 함께 남겼다. 수행 중 계획을 바꾼 사실도 연구의 재현성과 해석에 필요한 내용이다.

부정적 결과는 실패를 숨기기 위한 표현이 아니다. 주 가설인 검증본의 확정적 우위는 확인되지 않았고, 원래 대표 모델은 큰 수학 손실을 보였다. 마지막 보완에서 GSM8K 최종답 점수는 크게 회복했지만 전체 승격과 새 최종 확인은 이루어지지 않았다. 결과를 얻은 범위에서 결론을 좁히고 남은 조건을 미실행으로 표시했다는 점이 연구를 완결시키는 근거다.

향후 연구를 한다면 이미 사용한 개발셋과 분리한 새 과제, 학습률·목표 길이·데이터 조합의 요인별 비교, 실제 사람 검수와 여러 시드 확인이 필요하다. 이는 이번에 수행한 결과가 아니며 추가 실행을 시작하지 않았다. 현재 연구와 가중치 선택은 동결된 상태로 마감한다.

근거: 동결한 추가 실험과 구분된 기존 실측 기록 · 공개 데이터 키: recovery-research-close

VIII. 자료와 재현 안내

51. 자료 색인과 주요 방법 문헌

역사 자료: 초기 CoMPaSS 집중탐구계획서와 2026-10-22 클라우드 수정계획서를 직접 읽고 해시를 남겼다.8월 자유형 보고서·ARGOS_PILOT_EXPERIMENT_EVIDENCE_REPORT·argos_completion_report는 웹 프로젝트의 문서 검토 및 보존된 로컬 도구 출력과 대조했다. 초기 대화의 미확인 명칭·날짜는 사실로 확정하지 않았다. 개인 파일명·대화 URL은 공개하지 않는다.

실행·분석 자료: 저장소 docs/design_decisions.md, 원래 reports/argos-final-20261027/data, 후속 public-data의 개발·주장·쌍대·회복 실행 기록, 이번 synthesis_evidence·synthesis_activity·입력 manifest가 근거다. 기존 해시와 현재 보고서 산출물 해시는 구분하며, 공개 MANIFEST는 파일 경로·크기·SHA-256을 기록한다.

방법 문헌: LoRA: Low-Rank Adaptation, QLoRA, Distilling Step-by-Step, PaD: Program-aided Distillation. 작은 모델의 과제별 학습과 검증 가능한 설명 자료를 연구할 근거이며, 해당 논문의 알고리즘 전체·성능을 ARGOS에서 재현했다고 주장하지 않는다.

모델·데이터 원출처와 고정 리비전은 public_benchmark_sources, general_source_attribution, runtime_identity, training_configuration_frozen 및 회복 영수증에서 확인할 수 있다. 공개 모델·자료의 원 이용 조건은 별도로 적용되며 이 보고서 공개가 원 가중치의 사용권을 새로 부여하지 않는다. 문서 기준일은 2026년 10월 27일, 실험 상태는종료·동결이다.

근거: 첨부된 DOCX 두 파일의 직접 읽기와 SHA-256 · 공개 데이터 키: synthesis-source-register